

אופטימיזציה - עידן אלטר, תשפ"ה

רגב יחזקאל אימרה

March 5, 2025

1 מנהלה.

מרצה: עידן אלטר.

מייל alterdan@gmail.com.

שעות קבלה: בתיאום מראש.

ציון:

90% מבחן (חומר סגור, מותר מחשבון + דף נוסחאות)

10% תרגילי בית (שלושה לאורך הסמסטר).

2 הקדמה.

דוגמה 2.1. בעיה: במפעל לפחיות שימורים, רוצים לייצר פחיות עם נפח מקסימלי ושטח פנים מינימלי. אני רוצה שטח פנים מינימלי, כי המתכת שאני מייצר ממנה את הפחית עולה לי כסף ואני רוצה לבזבז כמה שפחות כסף.

כדי לפתור את הבעיה אני צריך להמיר את הבעיה המילולית למודל מתמטי, תוך כדי שאני אניח הנחות על המודל שלי לאורך הדרך. פתיוח המודל המתמטי:

הנחה ראשונה: הפחית בצורת גליל. זה לא אבסורדי כי בחיים האמיתיים פרט לקופסת סרדינים כל הפחיות שאנחנו רואים בצורת גליל.

לכן נסמן שנפח הגליל יהיה V ושטח הפנים של הגליל יסומן כתור S . אנו יודעים מהם V, S :

$$V = \pi r^2 h$$
$$S = 2\pi r^2 + 2\pi r h$$

כאשר r הוא רדיוס הבסיס של הגליל ו- h הוא גובה הגליל.

כעת אם אני רוצה למקסם את V ולמזער את S אני יכול פשוט לקחת את r להיות מספר שלילי גדול ככרצוני, לכן אנחנו נכתוב אילווצים $0 < r, h$. הנחה שנייה: יש תקציב של A שטח פנים לפחית.

בעית האופטימיזציה: בעצם במילים, אני רוצה למצוא את V המקסימלי עבורו שטח הפנים S קטן או שווה ל- A וכן $0 < r, h$. במתמטית:

$$P : \max_{r,h} V = \pi r^2 h$$
$$\text{s.t. } S = 2\pi r^2 + 2\pi r h \leq A$$
$$0 \leq r, h$$

איך פותרים:

תשובה מהירה: חפשו בגוגל gurobi, מכניסים את הבעיה והבעיה נפתרת.

תשובה פחות מהירה: מה gurobi עושה?

כותבים בצורה נוחה יותר (נדע בהמשך) לפתרון, כלומר לומר $z = r^2$ ואז פונקציית המטרה תהיה

$$\max_{z,h} V = \pi z h$$

כלומר אנחנו רוצים למקסם פונקציה ריבועית ולזה יש לנו הרבה אלגוריתמים מוכרים.


רוב הקורס יעסוק ב"בהינתן בעיית אופטימיזציה, מה האלגוריתם המתאים לפתרון שלה?".

דוגמה 2.2. (חזרה לבעיית הפחיות): מצאנו r, h , הממקסמים את V ומזערים את S אבל הם לא עובדים במציאות כי במפעל יש מכונה שמקבלת יריעת מתכת מגודל $A \times A$ והמכונה עוברת וחוטכת את החלקים שצריך לחתוך, וכל מה שנשאר הולך לפח. זה בזבוז! יכול להיות שמצאתי את הפתרון הכי טוב אבל שאנחנו מבזבזים יותר מדי מתכת בכל יריעה מה שהופך את הפתרון שלנו ללא הפתרון הכי טוב.

איך אני אביא לידי ביטוי את הבעיה החדשה?

המודל החדש: נשים את ריבוע המתכת במערכת צירים.

הנחה ראשונה: את הגוף גוזרים החל מ- $(0, 0)$ עד ל- (b, a) . (אפשר להוכיח שלא מאבדים ככה פתרונות טובים בעזרת אי שוויונים וסימטריה, במבחן חשוב לנמק למה בעזרת פתרון מתמטי!). נסמן: r -רדיוס הפחית. (x_1, y_1) מרכז מכסה 1, (x_2, y_2) מרכז מכסה 2.



דוגמה 2.3. מודל מתמטי:

$$P : \max S = \pi r^2 h$$

אילוצים:

1. אסור למעגל לצאת מיריעת המתכת: $r \leq x_i, y_i \leq A - r$
2. צריך שהמעגלים לא יחפפו: $2r \leq \left\| \begin{pmatrix} x_1 \\ y_1 \end{pmatrix} - \begin{pmatrix} x_2 \\ y_2 \end{pmatrix} \right\|$
3. צריך שהמעגלים לא יחפפו עם הגוף: אם המעגל i מעל הגוף (בתוך היריעה) אזי $a + r \leq y_i$
4. צריך שהמעגלים לא יחפפו עם הגוף: אם המעגל מימין לגוף: $b + r \leq x_i$
5. נניח שמגלגלים את הגוף סביב ציר ה- y (משיקולי סימטריה לא נאבד פתרונות). לכן $b = 2\pi r$
6. נניח שמגלגלים את הגוף סביב ציר ה- y (משיקולי סימטריה לא נאבד פתרונות). לכן $h = a$
7. אילוצי חיוביות: $0 \leq x_i, y_i, r, a$
8. בעיה: מה עושים עם אילוצים שתקפים רק לפעמים?

טריק: נוסיף משתנים בינאריים:

$$z_i = \begin{cases} 1 & \text{מעגל } i \text{ מעל הגוף} \\ 0 & \text{מעגל } i \text{ מימין לגוף} \end{cases}$$

נכניס את z_i לאילוצים:

אילוץ (3) הופך להיות $a + r \leq y_i + (1 - z_i) \cdot M$ כאשר M מספר חיובי גדול. כעת $z_i = 1$ לא קורה כלום: זה האילוץ הקודם. אחרת: M יהיה מספיק גדול כדי שאי השיוויון יתקיים תמיד. מהתבוננות בבעיה נבחר $M = 1.5A$ (כי $a \leq A$ וכן $r \leq \frac{1}{2}A$).
מאותו היגיון אילוץ (4) יהפוך להיות $b + r \leq x_i + z_i M$ כאשר שוב $M = 1.5A$.
הערה: כדאי לבחור M קרוב לחסם העליון שהוא יכול להיות (כלומר כדאי לבחור $M = 2A$ מאשר $M = 21000A$).
לכן הבעיה הופכת להיות:

$$\begin{aligned} P : \max_{x_i, y_i, a, b, z_i} V &= \pi r^2 h \\ \text{s.t. } r &\leq x_i, y_i \leq A - r \\ 2r &\leq \left\| \begin{pmatrix} x_1 \\ y_1 \end{pmatrix} - \begin{pmatrix} x_2 \\ y_2 \end{pmatrix} \right\| \\ b + r &\leq x_i + z_i M \\ a + r &\leq y_i + (1 - z_i) \cdot M \\ b &= 2\pi r \\ a &= h \\ x_i, y_i, a, b &\geq 0 \\ z_i &\in \{0, 1\} \end{aligned}$$

בעיה כזו נקראת בעיית אופטימיזציה עם משתנים בדידיים ורציפים עם אילוצים ריבועיים MIQCP. האלגוריתם מסובך אבל עובד טוב. בעיות נוספות מציאותיות:

1. סודוקו.
2. איך למקסם רווח של תחנת חשמל? (כי ברגע שאני מדליק את תחנת החשמל אני לא יכול לכבות אותה בשנייה).
3. איפה למקס אתר פסולת גרעינית? (אף אחד לא רוצה אותו קרוב).

אופטימיזציה ללא אילוצים.

נניח שנתונה לנו בעיה

$$P : \min_{x \in \mathbb{R}^n} f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$$

$$\text{s.t. } x \in M$$

כאשר x רציף כרגע. ככל ש- M , f פשוטות יותר, יש אלגוריתמים טובים יותר לבעיה.
דוגמה 2.4. נתונה הבעיה

$$\min_{x \in \mathbb{R}^n} c^T x + b$$

$$\text{s.t. } Ax \leq d$$

$$Bx = e$$

כאשר $b, c, d, e \in \mathbb{R}^n$ וכן $A, B \in \mathbb{R}^{n \times n}$.

זוהי בעיית אופטימיזציה ליניארית, יש אלגוריתמים מעולים לפתרון כמו אלגוריתם ה-simplex של דנציג משנת 1940.

3 מורד הגרדיאנט.

נתונה בעיית אופטימיזציה

$$P : \max_{x \in \mathbb{R}^n} f(x)$$

זוהי אופטימיזציה ללא אילוצים. נניח שיש ל- f צורה פשוטה:

$$f(x) = \frac{1}{2} x^T A x + b^T x + c$$

ל- f הזו יש 4 אפשרויות שונות לצורה:

1. קערה: קורה כאשר העקמומיות חיובית בכל כיוון, כלומר $A \succ 0$, מטריצה חיובית לחלוטין עם ע"ע חיובים.
2. קערה הפוכה: קורה כאשר העקמומיות שלילית בכל כיוון, כלומר $A \prec 0$, מטריצה שלילית לחלוטין עם ע"ע שליליים.
3. אוכף: כאשר יש ל- A ע"ע חיובים ושליליים.
4. צורה מנוונת: כאשר יש ל- A ע"ע 0.

אם $A \neq 0$ אזי אין נקודת מינימום (אפשרויות (2) ו-(3)), ובאפשרות (4) יהיו ∞ נקודות מינימום.

נתרכז במקרים שבהם $A \succ 0$.

למה המקרה הריבועי כל כך חשוב? תשובה: מאינפי 3, אם f חלקה מספיק אזי

$$f(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + \frac{1}{2} (x - x_0)^T H_f(x - x_0) + o(\|x - x_0\|^2)$$

מסקנה: אם x_0 נקודת מינימום של f (וגם $H_f(x_0) \succ 0$) אזי f דומה לקערה סביב x_0 .

סימון: x^* יהיה נקודת מינימום גלובאלית.

עוד תזכורות מאינפי 3:

1. אם $x^* = \arg \min_{x \in \mathbb{R}^n} f(x)$ אזי $\nabla f(x) = 0$.

2. $\nabla f(x)$ ניצב לקווי הגובה של f . פורמלית: $\{x \in \mathbb{R}^n | f(x) = a\}$ וכן $L_f(a)$ וכן $\{s \in \mathbb{R}^n | s = \frac{y_k - x}{\|y_k - x\|}, y_k \rightarrow x, f(y_k) = f(x)\}$ אזי $\nabla f(x) \perp T_f(x)$ לכל $s \in T_f(x)$. משמעות: ∇f ניצב לקווי הגובה $\iff \nabla f$ ניצב למשיקים לקו הגובה.

3. $\nabla f(x)$ הוא בכיוון של הגידול המהיר ביותר בערך של f , בסביבת x .

$-\nabla f(x)$ הוא הכיוון המהיר ביותר בערך f .

פורמלית: יהי $s \in \mathbb{R}^n$ ווקטור יחידה $\|s\| = 1$. נגדיר $\Delta(s) = \lim_{\alpha \rightarrow 0^+} \frac{f(x + \alpha s) - f(x)}{\alpha}$ להיות הנגזרת הכיוונית בכיוון s . אזי

$$\frac{\nabla f(x)}{\|\nabla f(x)\|} = \arg \max_s \Delta(s)$$

הוכחה. של (2): נקרב את f :

$$f(x) = f(x_0) + \langle \nabla f(x_0), x - x_0 \rangle + o(\|x - x_0\|)$$

כעת

$$f(y_k) = f(x) + \langle \nabla f(x), y_k - x \rangle + o(\|y_k - x\|)$$

אבל $f(y_k) = f(x)$ ולכן $x, y_k \in L_f(f(x))$ נחלק ב- $\|y_k - x\|$ ונקבל

$$0 = \left\langle \nabla f(x), \frac{y_k - x}{\|y_k - x\|} \right\rangle + \frac{o(\|y_k - x\|)}{\|y_k - x\|} \xrightarrow{k \rightarrow \infty} 0 = \langle \nabla f(x), s \rangle$$

■ כנדרש.

הוכחה. של (3):

$$f(x + \alpha s) = f(x) + \langle \nabla f(x), \alpha s \rangle + o(\|\alpha s\|)$$

נעשה אלגברה ונקבל

$$\Delta(s) = \lim_{\alpha \rightarrow 0^+} \frac{\langle \nabla f(x), \alpha s \rangle + o(\|\alpha s\|)}{\alpha} = \langle \nabla f(x), s \rangle$$

ולפי אי שוויון קושי שורץ

$$-\|\nabla f(x)\| \cdot \|s\| \leq \langle \nabla f(x), s \rangle \leq \|\nabla f(x)\| \cdot \|s\|$$

וכיוון ש- s הוא וקטור יחידה נקבל

$$-\|\nabla f(x)\| \leq \langle \nabla f(x), s \rangle \leq \|\nabla f(x)\|$$

והמקסימום מתקבל עבור $s = \frac{\nabla f(x)}{\|\nabla f(x)\|}$ והמינימום מתקבל עבור $s = -\frac{\nabla f(x)}{\|\nabla f(x)\|}$. ■

תזכורת אחרונה מאינפי 3:

מבחן הנגזרת השנייה:

1. אם $x^* = \arg \min f$ אזי $\nabla f(x^*) = 0$ וגם $H_f(x^*) \succeq 0$ (ע"ע אי שליליים).

2. אם $\nabla f(x^*) = 0$ וגם $H_f(x^*) \succ 0$ אזי $x^* = \arg \min f$.

בחזרה לאופטימיזציה: יש לנו בעיית

$$\min f(x) = \frac{1}{2} x^T A x + b^T x + c$$

אזי

$$\nabla f(x) = \frac{1}{2} A^T x + \frac{1}{2} A x + b$$

נניח כי $A^T = A$ (לא אבסורד כי f הולכת לקרב פונקציה אחרת בהמשך ו- A הולכת להיות H_f בערך ועבור f מספיק חלקה $H_f = H_f^T$). לפיכך:

$$\nabla f(x) = A x + b$$

אם $A \succ 0$ אזי היא הפיכה (כי אין לה ע"ע 0) ולכן $x^* = -A^{-1}b$ הפתרון היחיד של $\nabla f(x) = 0$ וזה חייב להיות מינימום לפי מבחן הנגזרת השנייה. מצאנו x^* , למה צריך אלגוריתם?

במציאות, לחשב A^{-1} זה מאוד יקר, וכדי למצוא $-A^{-1}b$ אני פותר את בעיית האופטימיזציה.

אלגוריתם 3.1. מורד הגרדיאנט:

1. בוחרים נקודת התחלה x_0 .

2. מחשבים את $\nabla f(x_0)$.

3. בוחרים "גודל צעד" $0 < \alpha$.

4. מחשבים $x_{k+1} = x_k - \alpha \nabla f(x_k)$.

נסמן בהמשך: $x = x_k$ המיקום הנוכחי, $x^+ = x_{k+1}$ המיקום הבא בתור.

"גודל צעד": נשים לב כי $\|x - x^+\| = \|\alpha \nabla f(x)\| = \alpha \underbrace{\|\nabla f(x)\|}_{\text{רוב הזמן לא 1}}$. גודל הצעד הוא כפולה של α ולא עצמו, אבל בכל זאת קוראים ל- α גודל הצעד, כי ככה.

3.1 חיפוש קו- line search.

כדי למצוא את α אנחנו מחפשים את המינימום של f על הקרן בכיוון $-\nabla f(x)$, כלומר נפתור

$$\min_{\alpha \geq 0} f(x - \alpha \nabla f(x))$$

יתרון: במקום אופטימיזציה במרחב \mathbb{R}^n עושים ב- \mathbb{R} (קל).

חיסרון: עבור f כללית זה בדר"כ עדיין קשה / יקר (כי צריך לפתור את הבעיה בכל איטרציה של מורד הגרדיאנט).
נניח לרגע כי

$$f(x) = x^T A x + b x + c, x \in \mathbb{R}^n$$

אפשר לפתור את line search במדויק:

נגזור:

$$\frac{\partial}{\partial \alpha} f(x - \alpha \nabla f(x)) = \langle \nabla f(x - \alpha \nabla f(x)), -\nabla f(x) \rangle$$

אבל

$$\nabla f(x) = A x + b$$

ולכן

$$\begin{aligned} \frac{\partial}{\partial \alpha} f(x - \alpha \nabla f(x)) &= -\langle A x - \alpha A \nabla f(x) + b, \nabla f(x) \rangle \\ &= -\langle \nabla f(x) - \alpha A \nabla f(x), \nabla f(x) \rangle \\ &= -\|\nabla f(x)\|^2 + \alpha \langle A \nabla f(x), \nabla f(x) \rangle \end{aligned}$$

נשווה ל-0: נקבל כי

$$\alpha^* = \frac{\|\nabla f(x)\|^2}{\langle A \nabla f(x), \nabla f(x) \rangle}$$

כעת מצאתי כי α^* נקודה קריטית. האם היא מינימום? נלך למבחן הנגזרת השנייה

$$\frac{\partial^2}{\partial \alpha^2} f(x - \alpha \nabla f(x)) = \frac{\partial}{\partial \alpha} (-\|\nabla f(x)\|^2 + \alpha \langle A \nabla f(x), \nabla f(x) \rangle) = \underbrace{\langle A \nabla f(x), \nabla f(x) \rangle}_{\text{קבוע}}$$

זה בהכרח חיובי כאשר $A \succ 0$ וכן $\nabla f(x) \neq 0$, כלומר α^* מינימום (גלובלי).

לפיכך, עבור f ריבועית:

$$\begin{aligned} x^+ &= x - \alpha^* \nabla f(x) \\ \alpha^* &= \frac{\|\nabla f(x)\|^2}{\langle A \nabla f(x), \nabla f(x) \rangle} \end{aligned}$$

שאלות:

1. מתי עוצרים?

כמה איטרציות צריך בשביל להגיע לפתרון טוב מספיק?
נוכיח בהמשך: $x_k \rightarrow x^* = \arg \min f$ תחת הנחות.
כמה מהר זה קורה?

2. איך בוחרים את α ?

α קטן \Leftarrow לא נתקדם הרבה \Leftarrow התכנסות איטית.
 α גדול \Leftarrow אולי x_k מתבדר

תשובות (נערכו במקרה הפרטי הנ"ל $f(x) = x^T A x + b x + c$):

1. נניח ובמזל יצא ש x_0 נבחר כך ש- $\nabla f(x_0)$ הוא ו"ע של A . אזי:

$$\alpha^* = \frac{\|\nabla f(x_0)\|^2}{\langle A \nabla f(x_0), \nabla f(x_0) \rangle} = \frac{1}{\lambda} \frac{\|\nabla f(x_0)\|^2}{\|\nabla f(x_0)\|^2} = \frac{1}{\lambda}$$

ולכן

$$x^+ = x - \frac{1}{\lambda} \nabla f(x)$$

$$\begin{aligned}\nabla f(x^+) &= Ax^+ + b \\ &= Ax - \frac{1}{\lambda} A \nabla f(x) + b \\ &= Ax - \frac{1}{\lambda} \cdot \lambda \nabla f(x) + b \\ &= Ax + b - \nabla f(x) \\ &= \nabla f(x) - \nabla f(x) \\ &= 0\end{aligned}$$

כלומר מצאתי נקודה קריטית! אבל f ריבועית לכן הנקודה הקריטית היחידה היא המינימום שאנחנו רוצים! לכן מצאנו כי

$$\arg \min f = x^+$$

טענה :

$$f(x^+) - f(x^*) \leq \left(\frac{k-1}{k+1} \right)^2 (f(x) - f(x^*))$$

כאשר

$$\begin{aligned}x^* &= \arg \min_{x \in \mathbb{R}^n} f \\ k &= \text{cond}(A) = \frac{\lambda_{\max}}{\lambda_{\min}}\end{aligned}$$

הוכחה : נוכיח

$$f(x^+) - f(x^*) \leq \frac{k-1}{k} (f(x) - f(x^*))$$

טענות עזר (נוכח כי $f(x) = x^T A x + b x + c$)
1) f זהה לקירוב טיילור שלה :

$$f(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle H_f(x)(y - x), y - x \rangle$$

הוכחה : נציב

$$\begin{aligned}\nabla f(x) &= Ax + b \\ H_f(x) &= A\end{aligned}$$

ונפשט.

(2) לכל $s \in \mathbb{R}^n$:

$$\lambda_{\min} \cdot \|s\|^2 \leq \langle As, s \rangle \leq \lambda_{\max} \|s\|^2$$

הערה 1 : ב- \mathbb{R}^2 זה משפט העקמומיות של אוילר : האמצע זה העקמומיות בכיוון של הגרף של f . הצדדים : ערכי העקמומיות הראשיים.
הערה 2 : עם משפט דומה, ז'ורדן הוכיח שקיימת ל- A פירוק SVD .

הוכחת $\lambda_{\min} \cdot \|s\|^2 \leq \langle As, s \rangle \leq \lambda_{\max} \|s\|^2$:

A סימטרית ולכן לכסינה אורתוגונלית כלומר קיים בסיס אורתונורמלי של ו"ע $\{v_1, \dots, v_n\}$. נסתכל על s בקואורדינטות הבסיס :

$$s = \sum_{i=1}^n \beta_i v_i$$

לכן :

$$\begin{aligned}\langle As, s \rangle &= \left\langle A \sum_{i=1}^n \beta_i v_i, \sum_{j=1}^n \beta_j v_j \right\rangle \\ &= \sum_{i=1}^n \sum_{j=1}^n \beta_i \beta_j \langle A v_i, v_j \rangle \\ &= \sum_{i=1}^n \sum_{j=1}^n \beta_i \beta_j \langle \lambda_i v_i, v_j \rangle \\ &= \sum_{i=1}^n \sum_{j=1}^n \lambda_i \beta_i \beta_j \langle v_i, v_j \rangle \\ &= \sum_{i=1}^n \lambda_i \beta_i^2\end{aligned}$$

אבל

$$\lambda_{\min} \|s\|^2 = \lambda_{\min} \sum_{i=1}^n \beta_i^2 \leq \langle As, s \rangle = \sum_{i=1}^n \lambda_i \beta_i^2 \leq \lambda_{\max} \sum_{i=1}^n \beta_i^2 = \lambda_{\max} \|s\|^2$$

טענה 3: f כלואה בין 2 קערות סימטריות.
הוכחה: נסמן

$$f_{\downarrow}(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{\lambda_{\min}}{2} \|y - x\|^2$$

$$f_{\uparrow}(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{\lambda_{\max}}{2} \|y - x\|^2$$

ונוכיח

$$f_{\downarrow}(y) \leq f(y) \leq f_{\uparrow}(y)$$

ההוכחה פשוטה: נציב את טענה (2) בטענה (1):

$$f(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \left\langle A(\underbrace{y-x}_s), \underbrace{y-x}_s \right\rangle \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \lambda_{\max} \cdot \|y - x\|^2 = f_{\uparrow}(y)$$

והכיוון השני דומה.

טענה 4:

$$f(x^*) \geq f(x) - \frac{1}{2\lambda_{\min}} \|\nabla f(x)\|^2$$

משמעות: אם $\|\nabla f(x)\|$ קטן, הנקודה x כמעט אופטימלית.

הוכחה: מסתכלים על החסם התחתון $f_{\downarrow}(y)$ ושואלים איפה מתקבל מינימום?

$$f_{\downarrow}(y) = y^T \begin{pmatrix} \lambda_{\min} & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \lambda_{\min} \end{pmatrix} y + \underbrace{\dots}_{\text{ליניארי ב-}y}$$

יחידה. נמצא אותה על ידי

$$\nabla_y f_{\downarrow}(y) = 0$$

ומקבלים

$$y^* = \arg \min_{y \in \mathbb{R}^n} f_{\downarrow}(y) = x - \frac{1}{\lambda_{\min}} \nabla_x f(x)$$

וכן

$$\begin{aligned} f_{\downarrow}(y^*) &= f(x) + \langle \nabla f(x), y^* - x \rangle + \frac{\lambda_{\min}}{2} \|y^* - x\|^2 \\ &= f(x) + \left\langle \nabla f(x), -\frac{1}{\lambda_{\min}} \nabla f(x) \right\rangle + \frac{\lambda_{\min}}{2} \left\| \frac{1}{\lambda_{\min}} \nabla f(x) \right\|^2 \\ &= f(x) - \frac{1}{\lambda_{\min}} \|\nabla f(x)\|^2 + \frac{\lambda_{\min}}{2} \left\| \frac{1}{\lambda_{\min}} \nabla f(x) \right\|^2 \\ &= f(x) - \frac{1}{2\lambda_{\min}} \|\nabla f(x)\|^2 \end{aligned}$$

אבל

$$f_{\downarrow}(y) \leq f(y)$$

וזה נכון גם ל- x אופטימלי $x^* = y$.
כלומר

$$f(x) - \frac{1}{2\lambda_{\min}} \|\nabla f(x)\|^2 \leq f(y)$$

ועכשיו אנחנו יכולים להוכיח את קצב ההתכנסות של מורד הגרדיאנט: נוכיח

$$f(x^+) - f(x^*) \leq \frac{k-1}{k} (f(x) - f(x^*))$$

תזכורת:

$$\begin{aligned} x^* &= \arg \min f \\ x^+ &= x - \alpha \nabla f(x) \\ \alpha &= \frac{\|\nabla f(x_0)\|^2}{\langle A \nabla f(x_0), \nabla f(x_0) \rangle} \end{aligned}$$

נגדיר :

$$x_t = x - t \nabla f(x)$$

לפי טענת עזר (3) כשמציבים בטענת עזר (4) $y = x_t$:

$$(*) f(x_t) \leq f_{\uparrow}(x_t)$$

וכן

$$\begin{aligned} f_{\uparrow}(x_t) &= f(x) + \langle \nabla f(x), x_t - x \rangle + \frac{\lambda_{\max}}{2} \|x_t - x\|^2 \\ &= f(x) - t \|\nabla f(x)\|^2 + \frac{\lambda_{\max}}{2} t^2 \|\nabla f(x)\|^2 \end{aligned}$$

ולפי (*) נקבל

$$(**) f(x^+) = \min_{t \geq 0} f(x_t) \leq \min_{t \geq 0} f_{\uparrow}(x_t)$$

נחפש :

$$\begin{aligned} \frac{\partial}{\partial t} f_{\uparrow}(x_t) &= 0 \\ -\|\nabla f(x)\|^2 + \lambda_{\max} t \|\nabla f(x)\|^2 &= 0 \\ t &= \frac{1}{\lambda_{\max}} \end{aligned}$$

זוה בהכרח מינימום כי פרבולה מחייכת, לכן

$$(***) f(x^+) \leq f_{\uparrow}(x_{t=\frac{1}{\lambda_{\max}}}) = f(x) - \frac{1}{\lambda_{\max}} \|\nabla f(x)\|^2 + \frac{\lambda_{\max}}{2} \cdot \frac{1}{\lambda_{\max}^2} \|\nabla f(x)\|^2 = f(x) - \frac{1}{2\lambda_{\max}} \|\nabla f(x)\|^2$$

מ(4) נקבל חסם ל- $\|\nabla f(x)\|^2$:

$$f(x) - \frac{1}{2\lambda_{\min}} \|\nabla f(x)\|^2 \leq f(x^*)$$

כלומר

$$f(x) - f(x^*) \leq \frac{1}{2\lambda_{\min}} \|\nabla f(x)\|^2$$

ולפי (***) נקבל

ונמשיך שבוע הבא (:

הערות :

(א) ככל ש- k גדול יותר, החסם גרוע יותר.

(ב) עוד איטרציה אחת משפרת את Δx פי כמה? אם מודדים את המרחק בערך f : פי $\left(\frac{k-1}{k+1}\right)^2$. לזה קוראים התכנסות ליניארית (קצב ליניארי), הכי איטי שיש בשימוש.

מתי מתקיים $\left(\frac{k-1}{k+1}\right)^2 = 0$? כאשר $k = 1$ כלומר $\lambda_{\max} = \lambda_{\min}$ אבל מכך זה אומר שיש ל- A רק ע"ע יחיד כלומר כל \mathbb{R}^n הוא מרחב עצמי של λ , אבל זה נכון כי $A^T = A$ ולכן A לכסינה אורתוגונלית, ואז $\nabla f(x)$ ו"ע של A לכל x . במקרה זה אם $f(x^+) - f(x^*) \leq 0$ כלומר $x^+ = \arg \min f$ ולכן $f(x^+) \leq f(x^*)$ כאשר $k >> 1$ ענק : החסם אומר שאנחנו בקושי מתקדמים בכל איטרציה, כלומר $\lambda_{\max} >> \lambda_{\min}$ ולכן אנחנו לא מתכנסים לערך מינימלי.

4 אלגוריתם Backtracking.

אנחנו מחפשים $\min f(x)$ במורד הגרדיאנט עבור f כללית, לא ריבועית.

הבעיה : לחשב $\alpha = \arg \min_{t \geq 0} f(x - t \nabla f)$ זה מאוד יקר/ בלתי אפשרי בכלל.

4.1 אלגוריתם Armijo.

קלט : $x, \nabla f(x), f(x)$.

פלט : גודל צעד α עבור דעיכת גרדיאנט $x - \alpha \nabla f$.

אתחול : $\alpha = 1$ (שרירותי לגמרי).

while :

כל עוד $f(x - \alpha \nabla f) > f(x) - \alpha \cdot \sigma \cdot \|\nabla f\|^2$, נעשה $\alpha = \rho \cdot \alpha$ (מקטינים את α).

ρ, σ הם פרמטרים שאנחנו בוחרים, מקובל לבחור $\rho = 0.5, \sigma \in (0.01, 0.2)$.

מה משמעות התנאי? בעזרת קירוב טיילור נקבל

$$\begin{aligned} f(x - \alpha \nabla f) &\approx f(x) - \alpha \langle \nabla f, \nabla f \rangle \\ &\approx \underbrace{f(x) - \alpha \|\nabla f\|^2}_{\text{המשיק ל-} f} \end{aligned}$$

בעצם המשיק (שמתקבל מקירוב טיילור) הוא הישר הכי קרוב ל- f בסביבת x , כלומר עבור α מספיק קטן אנחנו נרד במורד f אל עבר המינימום (המקומי), ואז מתישהו האלגוריתם יעצור. בשביל שזה יקרה צריך שהשיפוע של המשיק לא ישתנה מהר מדי.

בנוסף אפשר להוכיח שמורד הגרדיאנט עבור f עם H_f חסום מתכנס ליניארית.

5 אפשר מהר יותר?

אם f ריבועית, כלומר $f(x) = x^T A x + b x + c$ אזי קווי הגובה הם אליפסואידים או היפר ספירות. אם קווי הגובה הם היפר ספירות, אזי GD מתכנס באיטרציה אחת!

מכאן נקבל את הרעיון שאם אנחנו "נמחץ" את האליפסואידים לכדי ספירות, נמצא את המינימום / מקסימום ונחזור לקואורדינטות המקוריות שלנו, אזי האלגוריתם שלנו יעבור יותר טוב.

נחליף קואורדינטות:

$$\begin{aligned} x &\rightarrow z \\ f(x) &\rightarrow f(z) \\ z &= Q \cdot x \\ f(z) &= f(Qx) \end{aligned}$$

כלומר במעבר ל- z נמחץ צירים ארוכים ונמתח צירים קצרים כך שהערכים העצמיים של A יהיו שווים אחד לשני.

מה צריך: צריך למצוא את הצירים של האליפסואידים, כלומר הוקטורים העצמיים v_1, \dots, v_n של A ולמתוח / לכווץ בהתאם לערך העצמי המתאים.

נחשב:

$$f(x) = x^T A x$$

כאשר A סימטרית חיובית לחלוטין, לכן A לכסינה אורתוגונלית:

$$P^T A P = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix} = \Lambda$$

וכן

$$P = \begin{pmatrix} | & & | \\ v_1 & \cdots & v_n \\ | & & | \end{pmatrix}$$

עבור v_i וקטור עצמי המתאים לערך עצמי λ_i . לכן $A = P \Lambda P^T$. נציב את A ב- f :

$$\begin{aligned} f(x) &= x^T A x = \underbrace{x^T}_{y^T} \underbrace{P \Lambda P^T}_y x = y^T \Lambda y \\ &= y^T \begin{pmatrix} (\sqrt{\lambda_1})^2 & & \\ & \ddots & \\ & & (\sqrt{\lambda_n})^2 \end{pmatrix} y \\ &= y^T \begin{pmatrix} \sqrt{\lambda_1} & & \\ & \ddots & \\ & & \sqrt{\lambda_n} \end{pmatrix} \begin{pmatrix} \sqrt{\lambda_1} & & \\ & \ddots & \\ & & \sqrt{\lambda_n} \end{pmatrix} y \\ &\quad \underbrace{\hspace{10em}}_{\text{נסמן ב-}\sqrt{\Lambda}} \quad \underbrace{\hspace{10em}}_{z := (\sqrt{\lambda_1} y_1, \dots, \sqrt{\lambda_n} y_n)} \\ &= z^T \cdot I \cdot z \\ &= \tilde{f}(z) \end{aligned}$$

כלומר החלפנו קואורדינטות $z = \sqrt{\Lambda} P^T x$. עכשיו על $\tilde{f}(z)$ נפעיל GD . 9

אלגוריתם 5.1. מורד הגרדיאנט המשופר :

1. נגדיר $z = \sqrt{\Lambda} P^T x$.

2. נחשב $\tilde{f}(z) = z^T \cdot I \cdot z$.

3. נפעיל על $\tilde{f}(z)$ GD על $\tilde{f}(z)$.

(א) בחרו z_0 כלשהו.

(ב) $z^+ = z_0 - \alpha \nabla_z \tilde{f}(z_0)$ וכן $\alpha = \frac{\|\nabla f\|^2}{\langle A \nabla f, \nabla f \rangle} \Big|_{A=I} = 1$ בגלל שיש ל- I ע"ע יחיד $\lambda = 1$ נקבל כי $z^+ = \arg \min \tilde{f}(z)$.

4. $f(x) = \dots = \tilde{f}(z)$ וכן נגדיר $z^+ = \sqrt{\Lambda} P^T x^+$ כלומר $x^+ = P \Lambda^{-\frac{1}{2}} z^+$.

נקבל $x^+ = \arg \min f(x^+) = \dots \tilde{f}(z^+)$

נתרגם את האלגוריתם לאלגוריתם שעובד עם x בלבד :

תחילה אני רוצה להביע את $\nabla_z \tilde{f}(z)$ כתור פונקציה של x :

$$\begin{aligned} \nabla_z \tilde{f}(z) &= \nabla_z f(\sqrt{\Lambda} P^T x) \\ &= \nabla_z f(\sqrt{\Lambda} P^T x) \\ &\vdots \\ &= \Lambda^{-\frac{1}{2}} P^T \nabla_x f(x) \end{aligned}$$

נתרגם את האלגוריתם ל- x :

1. בחרו x_0 (על ידי $z_0 = \sqrt{\Lambda} P^T x_0$).

2. חשבו $\nabla_x f(x_0)$ (על ידי $\nabla_z \tilde{f}(z) = \Lambda^{-\frac{1}{2}} P^T \nabla_x f(x)$).

3. חשבו x^+ :

$$\begin{aligned} x^+ &= P \Lambda^{-\frac{1}{2}} z^+ \\ &= P \Lambda^{-\frac{1}{2}} (z_0 - \nabla_z \tilde{f}(z)) \\ &= P \Lambda^{-\frac{1}{2}} (\sqrt{\Lambda} P^T x_0 - \Lambda^{-\frac{1}{2}} P^T \nabla_x f(x)) \\ &= I \cdot x_0 - P \Lambda^{-1} P^T \nabla_x f(x) \\ &= x_0 - A^{-1} \nabla_x f(x_0) \end{aligned}$$

כעת מה אם f פונקציה כללית כלשהי? מי מחליפה את A שבשלב 3?

הקירוב הריבועי ל- f :

$$f(y) \approx f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} (y - x)^T H_f(x) (y - x)$$

כלומר במקופ A נבחר את H_f .

אלגוריתם 5.2. שיטת ניוטון :

1. בחר x_0 .

2. חשבו $x^+ = x - H_f^{-1}(x) \nabla f(x)$.

3. חזרו ל-2 איטרטיבית עד להתכנסות.

קשר לשיטת ניוטון רפסון? זו הכללה של השיטה, שם אנחנו פותרים משוואה אחת $g(x) = 0$ ובשיטת ניוטון אנחנו פותרים מערכת $\nabla f(x) = 0$.
תנאי עצירה :

1. נגמר התקציב.

2. $\|\nabla f\|$ נהיה קטן.

3. $\Delta f(x)$ קטן מאוד.

טענה 5.3. אם $g : \mathbb{R}^n \rightarrow \mathbb{R}$ עם גרדיאנט ∇g ליפשיצי (קיים) $L > 0$ כך ש- $\| \nabla g(x) - \nabla g(y) \| \leq L \|x - y\|$ אזי

$$|g(y) - g(x) - \langle \nabla g(x), y - x \rangle| \leq \frac{L}{2} \|y - x\|^2$$

הוכחה. נגדיר $h : \mathbb{R} \rightarrow \mathbb{R}$ על ידי $h(t) = E(x + t(y - x))$ זה השגיאה בקירוב טיילור ממעלה 1, ידוע $(\|y - x\|) \cdot o(\|y - x\|)$ לפיכך

$$\begin{aligned} h' &= \frac{\partial}{\partial t} (g(x + t(y - x)) - g(x) - \langle \nabla g(x), x + t(y - x) - x \rangle) \\ &= \frac{\partial}{\partial t} (g(x + t(y - x)) - t \langle \nabla g(x), y - x \rangle) \\ &= \langle \nabla g(x + t(y - x)) - \nabla g(x), y - x \rangle \end{aligned}$$

נשים \heartsuit : $h(0) = 0$ וכן $h(1) = E(y)$.

לפיכך:

$$E(y) = h(1) - h(0) = \int_0^1 h'(t) dt$$

כלומר

$$\begin{aligned} |E(y)| &= \left| \int_0^1 h'(t) dt \right| \leq \int_0^1 |h'(t)| dt \leq \int_0^1 |\langle \nabla g(x - t(y - x)) - \nabla g(x), y - x \rangle| dt \\ &\leq \int_0^1 \|\nabla g(x + t(y - x)) - \nabla g(x)\| \|y - x\| dt \\ &\leq \int_0^1 L \|x + t(y - x) - x\| \cdot \|y - x\| dt \\ &= \int_0^1 L \|y - x\|^2 t dt \\ &= \frac{L}{2} \|y - x\|^2 \end{aligned}$$

■ כנדרש.

טענה 5.4. נתונה $f: \mathbb{R}^n \rightarrow \mathbb{R}$ כך ש- H_f ליפשיצית עם קבוע $L > 0$. אזי $\nabla \frac{\partial f}{\partial x_i}$ ליפשיצי עם אותו קבוע.

הוכחה. נזכר כי $(H_f)_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$ וכן הוא סימטרי וגם $\nabla \frac{\partial f}{\partial x_i} = H_f \cdot e_i$ לפיכך:

$$\|\nabla \frac{\partial f}{\partial x_i}(y) - \nabla \frac{\partial f}{\partial x_i}(x)\| = \|(H_f(y) - H_f(x)) \cdot e_i\| \leq \|H_f(y) - H_f(x)\| \cdot \|e_i\| \leq L \|x - y\|$$

■ כנדרש.

טענה 5.5. נתונה $f: \mathbb{R}^n \rightarrow \mathbb{R}$ וכן H_f ליפשיצי עם $L > 0$. אזי

$$\|\nabla f(y) - (\nabla f(x) + H_f(x)(y - x))\| \leq \sqrt{n} \cdot \frac{L}{2} \|x - y\|^2$$

הוכחה. שוב נסמן $E(y) = \nabla f(y) - (\nabla f(x) + H_f(x)(y - x))$. נסתכל על הקואורדינטה ה- i של E :

$$\begin{aligned} E_i(y) &= \left\| \frac{\partial f}{\partial x_i}(y) - \frac{\partial f}{\partial x_i}(x) - H_{f_i}(x)(y - x) \right\| \\ &= \left\| \frac{\partial f}{\partial x_i}(y) - \frac{\partial f}{\partial x_i}(x) - \nabla \frac{\partial f}{\partial x_i}(x)^T (y - x) \right\| \end{aligned}$$

לפי טענה (2) אני יודע כי $\nabla \frac{\partial f}{\partial x_i}$ ליפשיצי עם L . לפי טענה (1) נקבל $|E_i(y)| \leq \frac{L}{2} \|y - x\|^2$ ומכאן

$$\begin{aligned} \|E(y)\|_2 &= \sqrt{\sum_{i=1}^n |E_i(y)|^2} \\ &\leq \sqrt{\sum_{i=1}^n \frac{L}{2} \|y - x\|^2} \\ &= \sqrt{n} \frac{L}{2} \|y - x\|^2 \end{aligned}$$

■ כנדרש.

טענה 5.6. תהי $f: \mathbb{R}^n \rightarrow \mathbb{R}$ גזירה לפחות פעמיים ברציפות וכן H_f ליפשיצי (קיים $L > 0$ כך ש- $\|H_f(x) - H_f(y)\| \leq L \|x - y\|$). נניח שנתון x_0 מספיק קרוב ל- x^* נקודת מינימום מקומי לא מנוונת (כלומר $\lambda_1(H_f(x)) > 0$) אזי שיטת ניוטון מתכנסת ל- x^* בסדר התכנסות ריבועי.

הוכחה. אפשר לחסום את השגיאה בקירוב מטיילור בעזרת קבוע ליפשיץ L .

נוכיח כי בשיטת ניוטון $\|x^+ - x^*\| \leq C \cdot \|x - x^*\|$.

אכן,

$$\begin{aligned} \|x^+ - x^*\| &= \|x - H_f^{-1}(x) \underbrace{\nabla f(x)}_{\substack{\text{נכתוב עם} \\ \text{פיתוח טיילור} \\ \text{סביב } x^*}} - x^*\| \\ &= \|x - x^* - H_f^{-1}(x) (\nabla f(x^*) + H_f(x) \cdot (x - x^*) + E)\| \\ &= \|x - x^* - H_f^{-1}(x) (H_f(x^*)(x - x^*) + E)\| \end{aligned}$$

כעת אני רוצה לומר כי $H_f^{-1}(x)$ היא כמעט ההופכית של $H_f(x)$ ואז הייתי נשאר עם

$$\begin{aligned} \|x^+ - x^*\| &= \|H_f^{-1}(x) \cdot E\| \\ &\leq \underbrace{\|H_f^{-1}(x)\|}_{:=C} \cdot \underbrace{\|E\|}_{\Omega(\|x-x^*\|^2)} \end{aligned}$$

ואז כביכול סיימתי. אי אפשר לעשות את זה כי $H_f^{-1}(x^*)$ היא לא באמת ההופכית של $H_f(x)$.

לכן אני נשאר עם

$$\begin{aligned} \|x^+ - x^*\| &= \|x - x^* - H_f^{-1}(x) (H_f(x^*)(x - x^*) + E)\| \\ &= \|H_f^{-1}(x) (H_f(x)(x - x^*) - H_f(x^*)(x - x^*) - E)\| \\ &\leq \|H_f^{-1}(x)\| \|H_f(x)(x - x^*) - H_f(x^*)(x - x^*) - E\| \\ &\leq \|H_f^{-1}(x)\| (\|H_f(x) - H_f(x^*)\| \|x - x^*\| + \|E\|) \\ &\leq \|H_f^{-1}(x)\| \left(L \cdot \|x - x^*\| \cdot \|x - x^*\| + \frac{\sqrt{n}}{2} \|x - x^*\|^2 \right) \end{aligned}$$

כעת x מספיק קרוב ל- x^* ומרציפות $\|H_f^{-1}(x)\|$ ערך זה כלוא בסביבת $\|H_f^{-1}(x^*)\|$ ובפרט חסום, כלומר קיבלנו

$$\begin{aligned} \|x^+ - x^*\| &\leq \|H_f^{-1}(x)\| \left(L \cdot \|x - x^*\| \cdot \|x - x^*\| + \frac{\sqrt{n}}{2} \|x - x^*\|^2 \right) \\ &\leq C \cdot \|x - x^*\|^2 \end{aligned}$$

השאלה היחידה שעולה היא האם $H_f^{-1}(x^*)$ תמיד קיים? התשובה היא כן כי דרשנו $H_f(x^*) \succ 0$.

כלומר הוכחנו את הטענה. ■

הערה 5.7. הערות:

1. אפשר להקטין את C (לא חשוב כי זה התכנסות ריבועית).
2. x^* יכולה להיות כח נקודה קריטית (השתמשנו בזה כשאמרנו $\nabla f(x^*) = 0$, אך זה נכון לא רק עבור נקודות מינימום אלא עבור כל נקודה קריטית). עדיין צריך לבדוק ש- x^* מינימום לאחר שהפעלתי את האלגוריתם.
3. אפשר להוכיח: אם האיטרציות שלי מתכנסות, אז $x \rightarrow x^*$ בהכרח x^* נקודה קריטית.
4. במציאות, שיטת ניוטון יקרה מדי.

5.1 שיטת קוואזי ניוטון.

הרעיון: לא מחשבים $H_f^{-1}(x)$ אלא קירוב שלו, מעיין אנלוגיה לדימיון בין שיטת ניוטון ושיטת המיתר.

למשוואה קוראים תנאי קוואזי ניוטון והיא

$$\nabla f(x^+) - \nabla f(x) = A(x^+ - x)$$

כאשר אני רוצה למצוא מטריצה A שתהפוך את הנ"ל לנכון, כי בד"כ $\nabla f(x)$, x נתונים.

בעיה: ב- A יש n^2 נעלמים. נדרוש סימטריה $A = A^T$ כלומר יש לנו $\frac{n^2+n}{2}$ נעלמים, בעוד שיש לי רק n משוואות.

הפתרון הוא שיש ∞ מטריצות A הפותרות את תנאי קוואזי ניוטון עבור $n > 1$. לכן המשתמש יבחר את המטריצה A לפי שיקול דעתו.

אלגוריתם 5.8. אלגוריתם קוואזי ניוטון:

קלט: $x, f, \nabla f(x)$ וכן A שהיא קירוב ל- $H_f^{-1}(x)$ מהאיטרציה הקודמת.

איטרציות:

1. נחשב את כיוון הירידה $d = A^{-1} \nabla f(x)$ (כיוון הירידה).

2. נבחר גודל צעד α (למשל עם כלל Armijo).

3. נעדכן $x^+ = x + \alpha d$.

4. חשבו את $\nabla f(x^+)$.

5. עדכנו את A ל- A^+ בעזרת תנאי קוואזי ניוטון: $A^+ = F(A, x, x^+ \nabla f(x), \nabla f(x^+))$ עבור F שבתקווה תהיה זולה לחישוב.

6. לזרו ל-1 עם $\nabla f(x^+), A^+ \cdot x^+$.

נשים \heartsuit כי בעצם צריך את A^{-1} ולא את A ולא נרצה להפוך את A מחדש בכל איטרציה (צריך לעדכן $A^{-1} \rightarrow A^{-1+}$ בצורה זולה).

הדרך הכי פופולארית לעדכן את A הינה שיטת $BFGS$:

הרעיון הוא שאנחנו יודעים כי A מקיימת את תנאי קוואזי ניוטון. נגדיר $A^+ = A + u \cdot u^T + v \cdot v^T$ עבור $u, v \in \mathbb{R}^n$. יש נוסחאות ל- u, v , לא נכתוב כי אין מה להגיד עליהן.

מציבים את A^+ בתנאי קוואזי ניוטון ומגלים שהתנאי עדיין מתקיים.

u, v נבחרו בצורה בלתי תלויה לינארית ולכן זה "כלל עדכון מדרגה 2" וזה זול: $O(n)$ פעולות לעדכון A .

אבל צריך A^{-1} , לשם כך יש את נוסחת שרמן מוריסון שגם זולה לחישוב אבל גם אותה לא נכתוב כי אין מה להרחיב עליה.

בעיה: צריך לשמור את A וזה מלא מלא טרה ביט זיכרון בשביל מודלים קטנים!

פתרון:

1. אפשר לשמור רק את u, v בזיכרון ואת A ההתחלתית (לרוב מנחשים $A_0 = I$) ואז זה הרבה פחות זיכרון.

2. אפשר לומר

$$d = A^{-1} \nabla f(x) \approx H_f^{-1}(x) \nabla f(x)$$

ואפשר לחפש דרך לחפש את כיוון הירידה בעזרת כיווני הירידה הקודמים

$$d_1, \dots, d_n \rightarrow d_{n+1}$$

בעזרת סטטיסטיקה וכו': אוספים סטטיסטיקה על עקמומיות f : אם x_i לא משתנה הרבה זמן אז להגדיל את קצב הלמידה (גודל הצעד שלו) כלומר להוסיף עקמומיות בכיוון הזה.

חלק II

אופטימיזציה עם אילוצים.

יש לי בעיה

$$\begin{aligned} P : \min & f(x) \\ \text{s.t.} & f_i(x) < 0 \\ & h_j(x) = 0 \end{aligned}$$

$$A = \left\{ x \in \mathbb{R}^n \mid \begin{array}{l} f_i(x) < 0 \\ h_j(x) = 0 \end{array} \right\}$$

אנחנו מחפשים מבחן פשוט שיגיד לנו $x^+ = \arg \min$ משהו דומה למבחן הנגזרת הראשונה $\nabla f = 0$ על הקבוצה A .
נגדיר בעיה חדשה:

$$Q : \min_{x \in \mathbb{R}^n} L(x)$$

ואני רוצה שהמינימום של Q יהיה המינימום של P . איך אני עושה את זה? נכניס את האילוצים לתוך $L(x)$ בדרך הזו:

$$L(x) = f(x) + \sum_{i \in I} \infty \cdot 1_+(f_i(x)) + \sum_{j \in J} \infty \cdot 1_{\neq 0}(h_j(x))$$

כאשר

$$1_+(u) = \begin{cases} 1 & u > 0 \\ 0 & u \leq 0 \end{cases}$$

וכן

$$1_{\neq 0}(u) = \begin{cases} 1 & u \neq 0 \\ 0 & u = 0 \end{cases}$$

טענה 5.9. $\arg \min Q = \arg \min P$ כלומר לפתור את P שקל לפתור את Q .

הוכחה. לכל $x \in A$ מתקיים $L(x) = f(x) < \infty$ ולכל $x \notin A$ מתקיים $L(x) = \infty$. לכן $\min Q$ מתקבל ב- A .
 אם $x^* = \arg \min Q$ אזי $f(x^*) = L(x^*) \leq L(x)$ לכל $x \in A$ ובפרט $f(x^*) \leq f(x)$ ולכן $x^* = \arg \min P$. הכיוון ההפוך עובד באותה צורה. ■

יש אלגוריתמים טובים לאופטימיזציה ללא אילוצים- נפעיל אותם על Q .

בעיה 1: $L(x) : \mathbb{R} \rightarrow \mathbb{R} \cup \{\infty\}$ ובעייתי לנו לעתעסק עם ∞ .

פתרון: בתקום ∞ נרשום M מספיק גדול כך שהמינימום על L יתקבל בוודאות בתוך A . כל מקרה דורש קצת מחשבה, כמה נמוך f יכולה לרדת מחוץ ל- A (חסם תחתון)- זה יהיה M . לכן

$$L(x) = f(x) + \sum_i M \cdot 1_+(f_i(x)) + \sum_j M \cdot 1_{\neq 0}(h_j(x))$$

בעיה 2: כשאני מחשב את ∇L אני צריך לגזור אינדיקטורים, וזה בעיה בשפה של התחום שלי.

פתרון: נחליף את האינדיקטורים בפונקציות גזירות. במקום $M 1_+(u_i)$ נכתוב $\lambda_i u_i$ ובמקום $M 1_{\neq 0}(u_j)$ נכתוב $\mu_j u_j$ (קירוב לינארי לאינדיקטור). לכן נקבל

$$L(x) = f(x) + \sum_i \lambda_i f_i(x) + \sum_j \mu_j h_j(x)$$

כאן כאשר $\lambda_i > 0$ אז כאשר $f_i(x) > 0$ הקנס שלי יותר גדול וכאשר $f_i(x) < 0$ נקבל "פרס" על זה שאנחנו בתוך התחום שלנו.
 מסקנה: לא בהכרח $\min L = \min f$.

נחפש $\min L$.

$$\inf_{x \in \mathbb{R}} L(x, \lambda, \mu) =: g(\lambda, \mu)$$

אנחנו משתמשים ב- \inf ולא ב- \min כי f לא בהכרח חסומה.

g נקראת הפונקציה הדואלית של f .

משפט 5.10. דואליות חלשה: אם לבעיה המקורית P יש פתרון x^* אז בהנחה ש- $\lambda_i \geq 0$ נקבל

$$g(\lambda, \mu) \leq \min_{x \in A} f(x)$$

הוכחה. אם $x^* = \arg \min P$ אז בפרט $x^* \in A$ כלומר $h(x^*) = 0$, $f_i(x^*) \leq 0$. לכן

$$L(x^*, \lambda, \mu) = f(x^*) + \underbrace{\sum_i \lambda_i f_i(x^*)}_{\leq 0} + \underbrace{\sum_j \mu_j h_j(x^*)}_{=0} \leq f(x^*) = \min_{x \in A} f(x)$$

כלומר

$$g(\lambda, \mu) = \inf L \leq L(x^*, \lambda, \mu) \leq \min_{x \in A} f(x)$$

■

מסקנה: למצוא \inf כלומר $\inf_x L$ עבור $\lambda \geq 0$ שקול למצוא חסם תחתון של P .

רעיון: נחפש את החסם התחתון הכי טוב. נגדיר

$$P_{LD} : \max_{\lambda, \mu} g(\lambda, \mu) \\ \text{s.t. } \lambda_i \geq 0$$

אם λ^*, μ^* פתרון של P_{LD} אזי

$$g(\lambda^*, \mu^*) \leq \min_{x \in A} f(x)$$

נשאל את השאלה מתי יהיה שוויון? אני מאוד רוצה שיוויון כי כאשר יש שיוויון אז אפשר לפתור את P_{LD} במקום P .

נגדיר את הערך הדואלי להיות

$$V_{LD} = \max_{\lambda \geq 0} g(\lambda, \mu)$$

כלומר הפתרון של P_{LD} , ואת הערך הפרימאלי להיות

$$V_P = \min_{x \in A} f(x)$$

בעצם הוכחנו כבר $V_{LD} \leq V_P$. נגדיר את פער הדואליות להיות $0 \leq V_P - V_{LD}$.

השאלה המרכזית היא מהם התנאים אין פער דואליות? מתי לפתור P_{LD} זהה לפתור P ?

למשל: ראינו בחקר ביצועים כי אם P לינארית, אין פער דואליות.

דוגמה 5.11. אם נתונה לנו הבעיה

$$\begin{aligned} P : \min & c^T x \\ \text{s.t.} & Ax = b \\ & x \geq 0 \end{aligned}$$

מיהי P_{LD} ?

נגדיר L :

$$L(x, \lambda, \mu) = c^T x - \lambda^T x + \mu^T (Ax - b) = (c - \lambda + A^T \mu)x - \mu^T b$$

ולכן

$$g(\lambda, \mu) = \inf (c - \lambda + A^T \mu)x - \mu^T b = \begin{cases} -\mu^T b & \text{else} \\ -\infty & c - \lambda + A^T \mu \neq 0 \end{cases}$$

לכן נבחר $\mu = (c - \lambda + A^T \mu)\mu$ ונקבל $L(x, \lambda, \mu) = \mu \|c - \lambda + A^T \mu\|^2 - \mu^T b$ ועבור $\mu \rightarrow -\infty$ ומקבלים $L \rightarrow -\infty$ כלומר הבעיה

$$\begin{aligned} P_{LD} : \max & g(\lambda, \mu) \\ \text{s.t.} & \lambda_i \geq 0 \end{aligned}$$

הופכת לבעיה

$$\begin{aligned} \max & -\mu^T b \\ \text{s.t.} & c - \lambda + A^T \mu \geq 0 \\ & \lambda_i \geq 0 \end{aligned}$$

וניתן לרשום אותה כתור

$$\begin{aligned} \max & -\mu^T b \\ \text{s.t.} & c + A^T \mu \geq 0 \\ & \lambda_i \geq 0 \end{aligned}$$

דוגמה 5.12. יש לנו בעיה

$$\begin{aligned} P : \min & f(x) = x^2 \\ \text{s.t.} & 1 - x^4 \leq 0 \end{aligned}$$

אינטואיטיבית אני יודע שהמינימום יהיה ב- ± 1 כי האילוץ שלי הוא $x \notin (-1, 1)$. נרצה לראות האם אנחנו מקבלים את זה מהמעבר לבעיה הדואלית:

$$\begin{aligned} L(x, \lambda) &= x^2 + \lambda(1 - x^4) \\ g(\lambda) &= \inf_{x \in \mathbb{R}} L(x, \lambda) = \begin{cases} -\infty & \lambda > 0 \\ 0 & \lambda = 0 \end{cases} \end{aligned}$$

וכן

$$\max g(\lambda) = 0 < 1 = \min f(x)$$

ואכן איבדנו משהו במעבר לבעיה הצמודה.

דוגמה 5.13. יש לנו בעיה

$$\begin{aligned} P : \min & f(x) = x^2 \\ \text{s.t.} & 1 - x^4 \leq 0 \end{aligned}$$

זו אותה בעיה כמו ממקודם, רק מנוסחת אחרת.

$$\begin{aligned} L(x, \lambda) &= x^2 + \lambda(1 - x^2) = (1 - \lambda)x^2 + \lambda \\ g(\lambda) &= \inf_{x \in \mathbb{R}} L(x, \lambda) = \begin{cases} -\infty & \lambda > 1 \\ \lambda & 0 < \lambda \leq 1 \\ 0 & \lambda = 0 \end{cases} \end{aligned}$$

נכתוב את הבעיה הדואלית:

$$P_{LD} : \max_{\lambda \geq 0} g(\lambda) = 1$$

כאשר $\lambda = 1$ ומצאנו $V_{LD} = V_P$.

חוץ מדוגמאות פשוטות, למצוא את $\inf L$ זה קשה עד בלתי אפשרי.

אם $\inf L$ מתקבל:

$$\inf_x L(x, \lambda, \mu) = \min_x L(x, \lambda, \mu)$$

$$x^* = \arg \min_x L(x, \lambda, \mu)$$

זה אומר כי x^* היא נגזרת קריטית של L (לפי מבחן הנגזרת הראשונה).

זה אומר כי $\nabla_x L(x, \lambda, \mu)$. אם L מספיק נחמד אז כל נקודה קריטית היא מינימום גלובאלי. (*) במקרה זה, אפשר לפתור בעיה פשוטה יותר:

5.2 הדואלית של וולף.

יש לנו הפעם בעיה דואלית

$$P_{WD} : \max L(x, \lambda, \mu)$$

$$\text{s.t. } \nabla_x L(x, \lambda, \mu)$$

$$\lambda_i \geq 0$$

לפי (*): אם x^* פתרון של P_{WD} :

$$\nabla_x L(x^*, \lambda^*, \mu^*) = 0$$

$$L(x^*, \lambda^*, \mu^*) = \min_x L(x^*, \lambda^*, \mu^*) = \max_{\lambda, \mu} \min_x L(x, \lambda, \mu)$$

וזה בדיוק פונקציית המטרה ב- P_{LD} .

בעיות אפשריות: אם L -יש נקודות קריטיות שהן מקס' מקומי אזי הן קריטיות ולכן בקבוצה האפשרית של P_{WD} , ואז

$$L(x^*, \lambda^*, \mu^*) \neq \min_x L(x^*, \lambda^*, \mu^*)$$

וזה אומר

$$P_{WD} \neq P_{LD}$$

השוואה ל- P_{LD} :

1. יותר קל לפתור את P_{WD} .

2. יש אילוצים יחסית פשוטים, יותר פשוטים מאלו של P .

3. x עדיין משתנה בבעיה: פתרון של P_{WD} הוא (x^*, λ^*, μ^*) .

דוגמה 5.14. נתונה $z \in \mathbb{R}^n$. מחפשים את המרחק של z מעל מישור $\{x | a^T x - b = 0\}$.
נסח כבעיית אופטימיזציה:

$$P : \min \|x - z\|$$

$$\text{s.t. } a^T x = b$$

הבעיה היא ש- $\| \cdot \|$ לא גזירה ב-0. נסח מחדש את הבעיה:

$$Q : \min \|x - z\|^2$$

$$\text{s.t. } a^T x = b$$

פונקציית המטרה תהיה

$$f(x) = \langle x - z, x - z \rangle$$

$$= x^T x - 2z^T x + z^T z$$

ומה שאנחנו לא רואים זה ש- $x^T I x = x^T I x$ כלומר f קערה.

$$L(x, \mu) = f(x) + \mu(a^T x - b)$$

אני רוצה לדעת האם L יפה.

L קמורה: כי ההסיאן של L לפי x הוא $H_{L,x} = I$, לכן יש מינימום גלובאלי יחיד.

לכן: $Q_{WD} = Q_{LD}$.

חישוב צד:

$$L(x, \mu) = x^T x - 2z^T x + z^T z + \mu(a^T x - b)$$

ולכן

$$\nabla_x L = 2x - 2z + \mu a$$

כלומר הדואלית של וולף הינה

$$Q_{WD} : \max_{x, \mu} L(x, \mu) \\ \text{s.t. } \nabla_x L = 2x - 2z + \mu a = 0$$

נחלץ את x :

$$x = z - \frac{\mu}{2} a$$

ונציב בפונקציית המטרה:

$$Q'_{WD} : \max_{\mu} L(z - \frac{\mu}{2} a)$$

שימו \heartsuit : זו בעיית אופטימיזציה במימד אחד בלי אילוצים! היא שקולה ל- Q_{WD} .

נסמן

$$g : \mathbb{R} \rightarrow \mathbb{R}$$

$$g(\mu) = L(z - \frac{\mu}{2} a)$$

נחשב

$$g'(\mu) = 0$$

ונקבל

$$\mu^* = z \cdot \frac{a^T z - b}{a^T a}$$

מחשבים $g''(\mu^*)$ ונקבלים

$$g''(\mu^*) = -\frac{a^T a}{2} < 0$$

כלומר μ^* היא מקסימום גלובאלי.

נחשב $x^* = z - \frac{\mu^*}{2} a$ ולכן

$$V_{WD} = L(x^*, \mu^*) = \left(\frac{|a^T z - b|}{\|a\|} \right)^2$$

מצאנו חסם תחתון ל- V_D , זה הקירוב למרחק של z מ- b $a^T x = b$. אולי מתקיים $V_P = V_{LD}$? (כן, אבל איך יודעים?).

למה 5.15. למת KKT:

אם (*) מתקיים ($P_{WD} = P_{LD}$) ונתונה (x^*, λ^*, μ^*) כך ש:

1. x^* אפשרית ב- P (מקיימת את האילוצים, $x^* \in M$).

2. (x^*, λ^*, μ^*) אפשרית ב- P_{WD} .

3. $f(x^*) = L(x^*, \lambda^*, \mu^*)$.

אזי x^* פתרון של P .

הוכחה. צריך להוכיח:

$$f(x^*) = \min_{x \in M} f(x) \\ \text{s.t. } x \in M$$

ידוע: $x^* \in M$ ולכן

$$f(x^*) \geq \inf_{x \in M} f(x) = V_P \geq V_{LD} = V_{WD} = \sup_{(x, \lambda, \mu) \in M_{WD}} L(x, \lambda, \mu) \geq L(x^*, \lambda^*, \mu^*)$$

אבל (3) אומר $f(x^*) = L(x^*, \lambda^*, \mu^*)$ כלומר סה"כ אנחנו מקבלים $f(x^*) \geq \dots \geq f(x^*)$ כלומר יש לנו סדרה של שוויונות. ■

מסקנה: $V_P = V_{WD} = V_{LD}$ כלומר אין פער דואליות.

הערה 5.16. בדוגמה הקודמת, בדקו שהתנאים של הלמה מתקיימים, כלומר $V_{WD} = V_P$ ולכן פתרון של Q_{WD} הוא פתרון של Q . (בעזרת אינפי 1 בלבד.)

$$P : \min f(x) \\ \text{s.t. } h_j(x) = 0$$

כלומר אין אילוץ \leq , אז לא צריך את תנאי (3) בלמה, הוא מתקיים אוטומטית.

הוכחה. ניזכר כי

$$L(x^*, \mu^*) = f(x^*) + \sum \mu_j^* h_j(x^*) = f(x^*)$$

ומכאן משתמשים בלמה. ■

הערה 5.17. אם אין אילוץ \leq , התנאים בלמה שקולים ל:

$$1. \quad h_j(x^*) = 0 \quad \text{לכל } j \text{ (שקול לומר } \nabla_{\mu} L(x^*, \mu^*) = 0 \text{)}$$

$$2. \quad \nabla_x L(x^*, \mu^*) = 0$$

שני התנאים האלו הם בדיוק כופלי לגראנז'.

זה נותן לי מוטיבציה לעשות אותו דבר גם כשיש לי אילוץ \leq , כלומר במקרה הכללי:

$$P : \min f(x) \\ \text{s.t. } f_i(x) \leq 0 \\ h_j(x) = 0$$

לכן הלמה הופכת להיות

$$1. \quad f_i(x) \leq 0, h_j(x) = 0$$

$$2. \quad \nabla_x L(x^*, \mu^*) = 0 \text{ וגם } \lambda_i^* \geq 0 \text{ לכל } i$$

$$3. \quad \sum \lambda_i^* f_i(x^*) = 0$$

כיוון שהסכום ב-(3) הוא אי חיובי, האילוץ (3) הופך להיות

$$\forall i, \lambda_i f_i(x^*) = 0 \quad (3)$$

נסמן את תנאי הלמה באותיות רומיות:

$$I : f_i(x) \leq 0$$

$$II : h_j(x) = 0$$

$$III : \lambda_i^* \geq 0 \text{ לכל } i$$

$$IV : \nabla_x L(x^*, \mu^*) = 0$$

$$V : \forall i, \lambda_i f_i(x^*) = 0$$

הגדרה 5.18. נק' (x^*, λ^*, μ^*) המקיימת $I - V$ נקראת נקודת KKT.

הערה 5.19. כל האלגוריתמים שיש לפתרון P מחפשים נקודת KKT.

דוגמה 5.20. נחפש

$$P : \min x \\ \text{s.t. } x^2 \leq 0$$

דוגמה מטופשת, האילוץ הוא $x = 0$ והפתרון אכן יהיה $x = 0$. האם $x = 0$ הוא בהכרח נקודת KKT?

$$L(x, \lambda) = x + \lambda x^2$$

הלגראנז' יאן קמור ולכן אני יכול לבדוק נקודות KKT. בנוסף כיוון ש- L קמור $P_{LD} = P_{WD}$ כלומר נקודת KKT היא תהיה מינימום גלובאלי.

נחפש נקודות KKT: לפי תנאי IV נקבל

$$(*) \nabla_x L = 1 + 2\lambda x = 0$$

ומתנאי V נקבל $\lambda x^2 = 0$. לפיכך, ל- $(*)$ אין פתרון!

מסקנה: אין נקודות KKT ובפרט $x = 0$ היא לא נקודת KKT.

טענה 5.21. אם נתונה (x^*, λ^*, μ^*) כך ש-

$$1. \quad x^* \text{ אופטימלית ב-} P$$

$$2. \quad (\lambda^*, \mu^*) \text{ אופטימלי ב-} P_{LD}$$

$$3. \quad V_{LD} = V_P \text{ אין פער דואליות,}$$

אזי נקודת KKT (x^*, λ^*, μ^*) .

הוכחה. קחו הוכחה מלמת KKT. ■

שאלה 5.22. מתי $V_P = V_{LD}$?

פתרון: תשובה 1: אם P לינארית:

$$\begin{aligned} \min c^T x \\ \text{s.t. } Ax = b \end{aligned}$$

ו- A מדרגה מלאה, אזי $V_P = V_{LD}$.
תשובה 2: אם

$$\begin{aligned} P : \min_y \max_x x^T A y \\ \text{s.t. } x, y \text{ וקטורי התפלגויות} \\ \sum x_i = 1 \\ x_i \geq 0 \end{aligned}$$

אפשר להוכיח:

$$\begin{aligned} P_{LD} : \max_x \min_y x^T A y \\ \text{s.t. } x, y \text{ וקטורי התפלגויות} \end{aligned}$$

אזי משפט המינימקס מוכיח $V_P = V_{LD}$.

תשובה 3: כאשר (א) הבעיה קמורה: f, f_i פונקציות קמורות, h_j ליניאריות.

(ב) יש לקבוצה האפשרית פנים: קיימת x כך ש- $f_i(x) < 0$ וכן $h_j(x) = 0$.

6 משמעות גיאומטרית של KKT.

הגדרה 6.1. נגדיר שהאילוץ f_i פעיל ב- x אם $f_i(x) = 0$.

נסמן: $I(x) = \{i | f_i(x) = 0\}$.

ניזכר בתנאי KKT:

$$f_i(x) \leq 0 : I$$

$$h_j(x) = 0 : II$$

$$\lambda_i^* \geq 0 : III$$

$$\nabla_x L(x^*, \mu^*) = 0 : IV$$

$$\forall i, \lambda_i f_i(x^*) = 0 : V$$

נשים ♥ כי אנחנו יכולים לפצל את זה לפי אילוצים פעילים:

$$i \in I(x) \text{ לכל } f_i(x) = 0 : 1$$

$$i \notin I(x) \text{ לכל } f_i(x) < 0 : 2$$

$$h_j(x) = 0 : 3$$

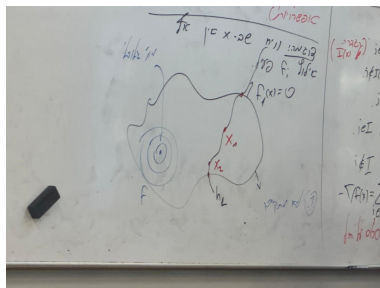
$$i \in I(x) \text{ לכל } \lambda_i^* \geq 0 : 4$$

$$i \notin I(x) \text{ לכל } \lambda_i^* = 0 : 5$$

$$\nabla f + \sum_{i \in I} \lambda_i \nabla f_i + \sum \mu_i \nabla h_j = 0 : 6$$

פעם $\sum_{i \in I}$ היה סכום על הכל, עכשיו זה על קבוצה קטנה יותר.

דוגמה 6.2. נניח כי בנקודה x אין אף אילוץ f_i פעיל.



דוגמה 6.3. אילו תנאי KKT מתקיימים?

(1) לא מתקיים. ✗

(2) $f_i(x) < 0$ גם ב- x_1, x_2 . ✓


(3) כנ"ל. ✓

(4) מתקיים באופן ריק. ✓

(5) נבחר $\lambda_i = 0$ לכל i . ✓

(6) נבחר $-\nabla f(x) = \mu_1 \nabla h_1$ ב- x_1 : $\nabla f \neq \mu \nabla h_1$ ולכן x_1 לא נקודת KKT. ב- x_2 : אם $\nabla f, \mu \nabla h_1$ ת"ל אזי (6) מתקיים ולכן x_2 נקודת KKT. משמעות: ∇f צריך להיות ניצב ל- $h_1 = 0$. אחרת: אפשר להטיל את $-\nabla f$ על האילוץ $h_1 = 0$ וללכת קצת בכיוון הזה כדי להוריד את ערך הפונקציה.

דוגמה 6.4. אין אילוץ שיוויון.



דוגמה 6.5. פונקציית המטרה היא מישור $f(x) = c^T x$.

שאלה: האם תיתכן x_1 נקודת KKT בפנים הקבוצה האפשרית? (כלומר $f_i(x_1) < 0$).

תשובה: תנאי (6) אומר לי $\nabla f = -\sum_{i \in I} \lambda_i \nabla f_i$. ב- x_1 מתקיים $I(x_1) = \emptyset$ ולכן (6) מתקיים $\iff \nabla f(x_1) = 0$. אבל f לינארית ולכן $\nabla f = c$ קבוע ובפרט $\nabla f \neq 0$ כלומר x_1 לא נקודת KKT.

ב- x_2 : $I(x_2) = \{1, 3\}$ ולכן $-\nabla f(x_2) = \lambda_1 \nabla f_1(x_2) + \lambda_3 \nabla f_3(x_2)$. שאלה: האם אפשר למצוא $\lambda_1, \lambda_3 \geq 0$? אם כן, כל השאר מתקיים אוטומטית ו- x_2 תהיה נקודת KKT. נסמן $F(x) = \{d | d = \alpha \nabla f_1(x_2) + \beta \nabla f_3(x_2) \wedge \alpha, \beta \geq 0\}$. הקבוצה הזאת היא כמו span רק עם מקדמי צירוף חיוביים וקוראים לזה חרוט.

החרוט F מצביע "החוצה" מהקבוצה האפשרית. את כל הכיוונים שבו אי אפשר להטיל על הקבוצה האפשרית וללכת בכיוון ההיטל בתוך הקבוצה האפשרית. מהצירוף אנחנו רואים ש- $-\nabla f$ לא ב- F גדול ולכן תנאי (6) לא יתקיים כלומר x_2 לא נקודת KKT.

ב- x_3 : $I(x_3) = \{1, 2\}$. (6) דורש $-\nabla f(x_3) = \lambda_1 \nabla f_1(x_3) + \lambda_2 \nabla f_2(x_3)$ וזה אכן מתקיים, לכן x_3 היא נקודת KKT. סיכום ביניים:

1. x^* נקודת KKT $\iff x^*$ מינימום גלובאלי.

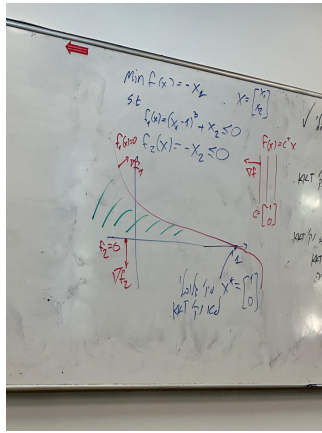
2. ראינו דוגמאות בהם x^* מינימום גלובאלי $\iff x^*$ נקודת KKT. מתי זה לא עובד? השאלה חשובה כי

(א) רוב האלגוריתמים מחפשים נקודות KKT.

(ב) אם x^* מינימום גלובאלי ו- x^* לא נקודת KKT אז האלגוריתם לא ימצא אותה.

דוגמה 6.6. נפתור את הבעיה

$$\begin{aligned} \min f(x) &= -x_1 \\ \text{s.t. } f_1(x) &= (x_1 - 1)^3 + x_2 \leq 0 \\ f_2(x) &= -x_2 \leq 0 \end{aligned}$$



דוגמה 6.7. באופן מפתיע נקבל $x^* = \begin{pmatrix} -1 \\ 0 \end{pmatrix}$ לא נקודת KKT. נבדוק את התנאים. ב- x^* , $I(x^*) = \{1, 2\}$.

1. $f_i(x^*) = 0$ ✓
 2. $f_i(x^*) < 0$ לכל $i \notin I$ מתקיים באופן ריק ✓
 3. $h_j(x^*) = 0$ באופן ריק ✓
 4. $\lambda_{1,2} \geq 0$ עוד לא ידוע.
 5. $\lambda_i = 0$ לכל $i \notin I$ מתקיים באופן ריק ✓
 6. $-\nabla f(x^*) = \lambda_1 \nabla f_1(x^*) + \lambda_2 \nabla f_2(x^*)$ -אולי קורה.
- $\nabla f_1 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ ולכן $\nabla f_1^* = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$
- $\nabla f = \begin{pmatrix} -1 \\ 0 \end{pmatrix}$ בעיה: ∇f הוא אפילו לא צירוף לינארית של $\nabla f_1, \nabla f_2$. לכן (6) לא מתקיים לא משנה מה נבחר להיות λ_1, λ_2 , כלומר x^* לא נקודת KKT.
- למה זה קרה? החרוט הנפרש על ידי $\nabla f_1, \nabla f_2$ אמור להיות הכיוונים בהם יוצאים מהקבוצה האפשרית. החרוט לא חירט והוא רק היה הישר $x_1 = 1$ ולכן קיבלתי שני כיוונים כחורט.
- אם מחשבים את $\nabla f_1, \nabla f_2$ קרוב ל- x^* הם בלתי תלויים לינארית אבל בגבול x^* נקבל ש- $\nabla f_1, \nabla f_2$ תלויים לינארית.
- משפט 6.8.** אם x^* נק מינימום מקומי של P ומתקיים $\{\nabla f_i(x^*) | i \in I(x^*)\} \cup \{\nabla h_j(x^*) | j \in J(x^*)\}$ בת"ל אז זו באמת נקודת KKT.

חלק III

ניתוח רגישות-CQ.

נניח:

1. $P_{LD}(\lambda^*, \mu^*)$ פתרון של הבעיה הדואלית
 2. אנחנו יודעים שאין פער דואליות: $V_P = V_{LD}$
- מה המשמעות של (λ^*, μ^*) ?

הגדרה 6.9. נגדיר את הבעיה המופרת להיות

$$P_\varepsilon : \min f(x) \\ \text{s.t. } f_i(x) \leq \varepsilon_i \\ h_j(x) = \delta_j$$

(בעיה המקורית $\delta_j = \varepsilon_i = 0$). הרעיון: להזיז טיפה את הקבוצה האפשרית.

נסמן $V(\varepsilon, P) = \inf P_\varepsilon$. יתכן שהפרענו לבעיה עד כדי כך שכבר אין פתרון. בגלל זה כותבים \inf במקום מינימום ואם אין פתרון ל- P_ε אז נסכים $\inf P_\varepsilon = -\infty$.

טענה 6.10.

$$V(\varepsilon, P) \geq V_P - \sum \lambda_i^* \varepsilon_i - \sum \mu_j^* \delta_j$$

משמעות:

- אם λ_i^* ממש גדול, אז $\varepsilon_i < 0$ יוביל עלייה משמעותית בערך פונקציית המטרה. כלומר, שווה להדק את החגורה באילוף f_i .
- אם $\lambda_i^* \approx 0$ הפרת האילוף f_i לא תשפיע על הפתרון באופן ניכר.
- אם $|\mu_j^*|$ גדול ממש ממש 0- (ענקי) אזי $\text{sign}(\mu_j^*)$ אומר לאיזה כיוון כדאי להפר את h כדי לשפר את הפתרון.

הוכחה. תהי x נקודה אפשרית ב- P_ε : $f_i(x) \leq \varepsilon_i, h_j(x) = \delta_j$. אם אין, אז $V(\varepsilon, \delta)$ והטענה נכונה. אם לא (נזכור שאין פער דואליות):

$$\begin{aligned} V_P = V_{LD} &= \inf_{y \in \mathbb{R}^n} (y, \lambda^*, \mu^*) \leq L(x, \lambda^*, \mu^*) = f(x) + \sum \lambda_i^* f_i(x) + \sum \mu_j^* h_j(x) \\ &\leq f(x) + \sum \lambda_i^* \varepsilon_i + \sum \mu_j^* \delta_j \end{aligned}$$

קיבלנו $V_P \leq f(x) + \sum \lambda_i^* \varepsilon_i + \sum \mu_j^* \delta_j$ נעביר אגף ונקבל $V_P - \sum \lambda_i^* \varepsilon_i - \sum \mu_j^* \delta_j \leq f(x)$. זה נכון לכל x אפשרי ב- P_ε ולכן אפשר לקחת \inf :

$$V_P - \sum \lambda_i^* \varepsilon_i - \sum \mu_j^* \delta_j \leq \inf_{x \in P_\varepsilon} f(x) = V(\varepsilon, P)$$

■ כנדרש.

טענה 6.11. אם $V(\varepsilon, P)$ חלקה אז $-\lambda_i, \frac{\partial V}{\partial \varepsilon_i} \Big|_{\varepsilon, \delta=0} = -\lambda_i, \frac{\partial V}{\partial \delta_j} \Big|_{\varepsilon, \delta=0} = -\mu_j$. משמעות: הפרה של אילוף i ב- ε_i משמע שיפור / הרס של $-\lambda_i \varepsilon_i$.

הוכחה. נסמן $\varepsilon_t = t \cdot e_i$. מהטענה הקודמת $V(\varepsilon_t, 0) \geq V_P - \lambda_i^* t$. מכך אני מסיק 2 דברים:

$$\begin{aligned} 1. \quad t > 0: \quad \frac{V(0+t \cdot e_i, 0) - V(0, 0)}{t} &\geq -\lambda_i^* \\ 2. \quad t > 0: \quad \frac{V(0+t \cdot e_i, 0) - V(0, 0)}{t} &\leq -\lambda_i^* \end{aligned}$$

אגף שמאל בשני האי שוויונות שואף ל- $\frac{\partial V}{\partial \varepsilon_i} \Big|_{\varepsilon, \delta=0}$ לפי הגדרת הנגזרת הכיוונית, והוא גדול וקטן מ- λ_i^* בו זמנית ולכן שווה להם. עם δ_j בדומה. ■

אחד התנאים ב-KKT היה $\lambda_i f_i = 0$. קיבלנו שיפור: אם $f_i < 0$ ו- i פעיל אז $\lambda_i = 0$ כלומר אפשר להפר את הבעיה המקורית ו- x^* עדיין יהיה פתרון. אם $f_i = 0$ אז λ_i אומר כמה נזק יקרה מהפרת אילוף זה.

הגדרה 6.12. תהי $M \subseteq \mathbb{R}^n$ וכן $x \in M$. נגדיר את החרוט המשיק להיות

$$T_M(x) = \left\{ d \mid \exists 0 < \{t_k\}_{k=1}^\infty, \{d_k\}_{k=1}^\infty \in \mathbb{R}^n \text{ s.t. } d_k \rightarrow d, t_k \rightarrow 0, \forall k: x + t_k d_k \in M \right\}$$

אינטואיטיבית $T_M(x)$ הוא כל הכיוונים מהם אפשר להגיע אל x תוך כדי תנועה מתוך M .

הערה 6.13. $0 \in T_M(x)$ תמיד כי עבור $d = 0$ בוחרים $d_k = 0$ ואז $x + t_k d_k = x \in M$.

הערה 6.14. בגלל שאמרנו $0 \in T_M(x)$ אזי כדי לראות את החרוט המשיק בנקודה x עצמה נתבונן ב- $T_M(x) + x$.

טענה 6.15. אם $d \in T_M(x)$ אז לכל $\alpha > 0$ מתקיים $\alpha d \in T_M(x)$.

הוכחה. נוכיח $\alpha d \in T_M(x)$, כלומר נוכיח:

$$x + t'_k d'_k \in M \quad (3) \quad 0 < t'_k \searrow 0 \quad (2) \quad d'_k \rightarrow \alpha d \quad (1)$$

נגדיר $d'_k = \alpha d_k$ כלומר $d'_k \rightarrow \alpha d$ כלומר (1) מתקיים. נגדיר $t'_k = \frac{1}{\alpha} t_k < 0$ ואכן $t'_k \searrow 0$ כלומר (2) מתקיים. באשר ל-(3):

$$x + t'_k d'_k = x + \frac{1}{\alpha} t_k \alpha d_k = x + t_k d_k \in M$$

■ כלומר גם (3) מתקיים ולכן $\alpha d \in T_M(x)$.

למה הדבר הזה חשוב:

טענה 6.16. אם x^* מינימום לוקאלי של f ב- M אזי $\langle \nabla f(x^*), d \rangle \geq 0$ לכל $d \in T_M(x)$.

הוכחה. יהי $d \in T_M(x^*)$ עם t_k, d_k המתאימות. נסתכל על קירוב טיילור:

$$f(x^* + t_k d_k) = f(x^*) + \langle \nabla f(x^*), t_k d_k \rangle + o(\|t_k d_k\|)$$

נזכור ש- x^* מינימום ב- M כלומר $f(x^* + t_k d_k) \geq f(x^*)$. לפיכך נקבל

$$0 \leq \langle \nabla f(x^*), t_k d_k \rangle + o(\|t_k d_k\|)$$

נחלק ב- t_k ונקבל

$$0 \leq \underbrace{\langle \nabla f(x^*), d_k \rangle}_{\rightarrow \langle \nabla f(x^*), d \rangle} + \underbrace{o(\|d_k\|)}_{\rightarrow 0}$$

■ כלומר $\langle \nabla f(x^*), d \rangle \geq 0$ כנדרש.

משמעות: לכל כיוון לתוך M , f לא יורדת.

מסקנה: אם x בפנים של M (ואז $T_M(x) = \mathbb{R}^n$) אז $\langle \nabla f(x^*), d \rangle \geq 0$ לכל $d \in T_M(x)$.
זה מעניין כי אז $\langle \nabla f(x^*), d \rangle \geq 0$ וגם $\langle \nabla f(x^*), -d \rangle \geq 0$ כלומר $\langle \nabla f(x^*), d \rangle = 0$ לכל d אבל אז זה נכון גם עבור $d = \nabla f(x^*)$ כלומר $\|\nabla f(x^*)\| = 0$ ולכן $\nabla f(x^*) = 0$.

זו בעצם הכללה לתנאי נגזרת הראשונה.

הערה 6.17. הטענה ההפוכה לא נכונה. יתכן $\langle \nabla f(x^*), d \rangle \geq 0$ אבל x^* לא מינימום ב- M .

דוגמה 6.18. נתבונן ב-

$$\begin{aligned} \min y \\ \text{s.t. } y = -x^2 \end{aligned}$$

בבירור אין מינימום גלובאלי. קצת יותר קשה לראות שאין מינימום לוקאלי. נסתכל על $\begin{pmatrix} 0 \\ 0 \end{pmatrix}$. זה לא מינימום לוקאלי: $\begin{pmatrix} t \\ -\frac{t^2}{2} \end{pmatrix} \rightarrow \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

היא נקודה אפשרית ובה מתקיים $f(0, 0) \geq f\left(-\frac{t^2}{2}\right)$. נראה כי $\langle \nabla f(x^*), d \rangle \geq 0$. נמצא את החרוט המשיק:

נטען כי $T_M = \left\{ \begin{pmatrix} d^1 \\ d^2 \end{pmatrix} \mid d^2 \geq 0 \right\}$ (זה אינדקסים למעלה, לא חזקות). נוכיח:

\supseteq : קל. יהי $d = \begin{pmatrix} d^1 \\ d^2 \end{pmatrix}$ עם $d^2 \geq 0$. ברור ש- $d_k = d$, $t_k = \frac{1}{k}$ ואז נוכיח $x + d_k t_k \in M$ אבל $(t_k d^1)^2 \geq 0 \geq -t_k d^2$ כלומר $y_d \geq -x_d^2$ ולכן $x + d_k t_k \in M$.

\subseteq : יהי $d = \begin{pmatrix} d^1 \\ d^2 \end{pmatrix}$ כאשר $d \in T_M$ ונניח בשלילה $d^2 > 0$. הרעיון: $-x^2$ מתאפס מהר יותר מכל ישר. $x + t_k d_k$ "מתכנס לתנועה" על הישר d בכיוון ה-0. \Leftarrow מתישהו, $x + t_k d_k$ יהיה קרוב מאוד לקרן בכיוון d , אבל הקרן הזאת תהיה מתחת ל- $-x^2$ $\Leftarrow x + t_k d_k \notin M$ לא משנה מיהם t_k, d_k . נראה את זה באופן פורמלי: $d \notin M$.

$d \in T_M \Leftarrow$ קיימות $d \rightarrow d_k$, $0 < t_k \searrow 0$ וכן $x + t_k d_k \in M$. מ- $d_k \rightarrow d$ הקבל שלכל $\varepsilon > 0$ החל מ- k מסויים נקבל $\|t_k d_k - d\| \leq \varepsilon$. נניח $t_k d_k^2 > -(t_k d_k^1)^2$ אבל ידוע $t_k d_k \in M$ ולכן $\forall i \in \{1, 2\} : t_k d_k^i < t_k (d^i + \varepsilon')$ $\Leftarrow |t_k d_k^2 - t_k d^2|, |t_k d_k^1 - t_k d^1| < t_k \varepsilon' \Leftarrow t_k d \leq t_k \varepsilon$ בה"כ $0 < t_k d_k^1$ סה"כ נקבל

$$t_k(d^2 + \varepsilon') \geq t_k d_k^2 \geq -(t_k d_k^1)^2 > -(t_k(d^1 + \varepsilon'))^2$$

ונקבל

$$t_k(d^2 + \varepsilon') > -(t_k(d^1 + \varepsilon'))^2$$

כלומר החל מ- k כלשהו

$$t_k \geq \underbrace{-\frac{d^2 + \varepsilon'}{(d^1 + \varepsilon')^2}}_{d^2 < 0 \text{ חיובי כי}} > 0$$

וזו סתירה לכך ש- $t_k \rightarrow 0$.

מסקנה: $d^2 \geq 0$.

מסקנה: לא כיף לחשב ככה $T_M(x)$. מה עושים? מנסים דרך הגדרה אחרת.

הגדרה 6.19. עבור הבעיה

$$\begin{aligned} \min f(x) \\ \text{s.t. } f_i \leq 0 \\ h_j = 0 \end{aligned}$$

עם קבוצת האילוצים הפעילים

$$I(x) = \{i \mid f_i(x) = 0\}$$

נגדיר את קבוצת האילוצים האפשריים אחרי שעברה ליניאריזציה (קבוצת הכיוונים האפשריים) להיות

$$F(x) = \left\{ d \mid \begin{array}{l} \forall j : \langle \nabla h_j(x), d \rangle = 0 \\ \forall i \in I : \langle -\nabla f_i(x), d \rangle \geq 0 \end{array} \right\}$$

כדי לבדוק $d \in F$? צריך לחשב מספר סופי של מכפלות פנימיות. הרעיון: $F(x)$ אמורה להיות קירוב מספיק טוב ל- $T_M(x)$. הערות:

הערה 6.20. אותם סימנים מופיעים בתנאי KKT ובהגדרת F . לא צירוף מקרים.

הערה 6.21. $T_M(x)$ זה תכונה של M בלבד. $F(X)$ משתנה בהתאם ל- h_j, f_i שבחרנו כדי לתאר את M . אולי יהיה צריך לבחור את h_j, f_i בצורה נכונה כדי ש- $T_M(x) = F(x)$.

טענה 6.22. $F(x)$ חרוט.

הוכחה. נובע מליניאריות המכפלה הפנימית

$$\langle -\nabla f(x^*), d \rangle \geq 0 \Rightarrow \langle -\alpha \nabla f(x^*), d \rangle \geq 0, \alpha > 0$$

■ כנדרש.

דוגמה 6.23. נניח $M = \{(x, y) | \underbrace{x^2 + y^2 - 2}_{h_1} = 0\}$ ונסמן $\bar{x} = (-\sqrt{2}, 0)$. מהם $T_M(\bar{x}), F(\bar{x})$?

נטען כי $T_M(\bar{x}) = \text{span}\{e_2\}$ (לא נוכיח).

נטען $F(\bar{x}) = \{d | \langle \nabla h_1(\bar{x}), d \rangle = 0\}$. אכן $\nabla h_1 = \begin{pmatrix} 2x \\ 2y \end{pmatrix}$, $\nabla h_1(\bar{x}) = \begin{pmatrix} -\sqrt{8} \\ 0 \end{pmatrix}$ וכן $\langle \nabla h_1(\bar{x}), d \rangle = 0 \iff d = \begin{pmatrix} 0 \\ s \end{pmatrix}$.

דוגמה 6.24. נניח $M = \{(x, y) | \underbrace{(x^2 + y^2 - 2)^2}_{h_1} = 0\}$ ונסמן $\bar{x} = (-\sqrt{2}, 0)$. מהם $T_M(\bar{x}), F(\bar{x})$?

נשים $\heartsuit, h_2(x) = 0 \iff h_1(x) = 0$ ולכן M זהה לזו בדוגמה קודמת.

מי זה $F(\bar{x})$?

$$F(\bar{x}) = \{d | \langle \nabla h_2(\bar{x}), d \rangle = 0\}$$

אך כרגע

$$\nabla h_2 = 2(x^2 + y^2 - 2) \begin{pmatrix} 2x \\ 2y \end{pmatrix}$$

אבל $\bar{x} \in M$ ולכן $\langle \nabla h_2(\bar{x}), d \rangle = 0$ לכל $d \in \mathbb{R}^n$ כלומר $F(\bar{x}) = \mathbb{R}^n$.

טענה 6.25. $T_M(x) \subseteq F(x)$.

הוכחה. יהי $d \in T_M$ עם t_k, d_k מתאימות. ידוע:

$$x + t_k d_k \in M \quad (1)$$

$$M = \left\{ x \mid \begin{matrix} f_i(x) \leq 0 \\ h_j(x) = 0 \end{matrix} \right\} \quad (2)$$

לפיכך $h_j(x + t_k d_k) = 0$ מפיתוח טיילור נקבל

$$0 = h_j(x) + \langle \nabla h_j(x), t_k d_k \rangle + o(t_k)$$

נחלק ב- t_k ונקבל

$$0 = \langle \nabla h_j(x), t_k \rangle + \underbrace{\frac{o(t_k)}{t_k}}_{\xrightarrow{k \rightarrow \infty} 0}$$

כלומר בגבול $k \rightarrow \infty$ נקבל $\langle \nabla h_j(x), t_k \rangle = 0$.

לכן עבור i פעיל ב- x : $f_i(x) = 0$ וכן $f_i(x + t_k d_k) \leq 0$. לפי פיתוח טיילור נקבל...

$$\langle -\nabla f_i(x), d \rangle \geq 0$$

■ ולכן $d \in F$ לפי הגדרת F .

משפט 6.26. אם x^* מינימום לוקאלי וגם $T_M(x^*) = F(x^*)$ אז x נקודת KKT.

משפט 6.27. אם $\{\nabla f_i(x) | i \in I\} \cup \{\nabla h_j\}$ בת"ל אז $F(x) = T_M(x)$.

הוכחה. צ"ל בעצם $F(x) \subseteq T_M(x)$.

ניסיון ראשון: נתון $\{\nabla f_i(x) | i \in I\} \cup \{\nabla h_j\}$ בת"ל. יהי $d \in F$. צריך למצוא $d_k \rightarrow d, t_k \searrow 0$ כך ש- $z_k = x + t_k d_k \in M$. זה מתקיים $\iff f_i(z_k) \leq 0, h_j(z_k) = 0, \forall i, j$. לא משנה מה, יצא ש- $z_k \rightarrow x$. אם f_i לא פעיל ב- x נקבל $f_i(x) < 0$ ואז נקבל גם $f_i(z_k) < 0$ החל מ- k מסויים.

מסקנה: לא צריך לדאוג לגבי f_i , האילוץ יתקיים ב- z_k .

הערה: אם f_i פעיל, $f_i(x) = 0$. בהחלט יתכן $f_i(z_k) > 0$ אינסוף פעמים - כלומר צריך להשקיע מחשבה בבחירה של d_k, t_k כדי להימנע מזה.

עבור f_i פעיל: נעשה פיתוח טיילור ונקבל

$$\begin{aligned} f_i(z_k) &\approx \underbrace{f_i(x)}_{=0} + t_k \langle \nabla f_i(x), d_k \rangle \\ &= t_k \langle \nabla f_i(x), d_k \rangle \\ &\xrightarrow{k \rightarrow \infty} \underbrace{t_k \langle \nabla f_i(x), d \rangle}_{\substack{0 \leq \quad \leq 0}} \end{aligned}$$

מסקנה: אם נבחר z_k נכון (\approx לא עושה בעיות) נקבל $f_i(z_k) \leq 0$.

בדומה:

$$h_j(z_k) \approx t_k \underbrace{\langle \nabla h_j(x), d_k \rangle}_{=0} = 0$$

לכן $z_k \in M$ וסיימו.

איך נדלג על סימני \approx ? נכתוב משוואה ונקווה לטוב. נחפש z שפותר את המשוואה במדויק:

$$\star \begin{cases} f_i(z) = t \langle \nabla f_i(x), d \rangle \\ h_j(z) = t \langle \nabla h_j(x), d \rangle \end{cases}$$

נעלים: t, z . נניח שמצאנו פתרון עבור $t = \frac{1}{k}$ נקבל שאנחנו יודעים $(z_k, \frac{1}{k} = t_k)$ ולכן

$$\frac{1}{k} \langle \nabla f_i(x), d_k \rangle + o(\frac{1}{k}) = f_i(z_k) = \frac{1}{k} \langle \nabla f_i(x), d \rangle$$

נכפיל ב- k :

$$\langle \nabla f_i(x), d_k \rangle + \underbrace{k \cdot o(\frac{1}{k})}_{=o(1)} = \langle \nabla f_i(x), d \rangle$$

נשאיף את k לאינסוף ונקבל

$$(1) \langle \nabla f_i(x), d_k \rangle \rightarrow \langle \nabla f_i(x), d \rangle$$

בדומה,

$$(2) \langle \nabla h_j(x), d_k \rangle \rightarrow \langle \nabla h_j(x), d \rangle$$

סיכום ביניים: $z_k \in M, t_k = \frac{1}{k} \searrow 0$ כי (z_k, t_k) פתרון של \star . נשאר רק להראות $d_k \rightarrow d$ ולהסיק ש- $d \in M$ לפי ההגדרה.

שאלה: האם $(1), (2) \Rightarrow (3)$? תשובה: אם $\{\nabla f_i(x) | i \in I\} \cup \{\nabla h_j(x)\}$ בסיס אורתונורמלי אז כן. נוכיח:

$$\{\nabla f_i(x) | i \in I\} \cup \{\nabla h_j(x)\} = \{\nabla C_i | i = \underbrace{1, \dots, p}_{\text{מספר } h_j\text{-ה}} \underbrace{p+1, \dots, \overbrace{|I|+p}^{:=\ell}}_{\text{מספר } f_i\text{ פעילים}}\}$$

נסמן p מספר h_j -ה שיש לי. נסמן ℓ מספר f_i פעילים.

$$\begin{aligned} d_k &= \sum_{i=1}^n \langle \nabla C_i, d_k \rangle \nabla C_i \\ (1), (2) \downarrow k &\rightarrow \infty \\ d &= \sum_{i=1}^n \langle \nabla C_i, d \rangle \nabla C_i \end{aligned}$$

מסקנה: $d_k \rightarrow d$ כלומר $d \in T_K$.

האם באמת אפשר לפתור את \star ?

נסמן

$$C(z) = \begin{pmatrix} C_1(z) \\ \vdots \\ C_n(z) \end{pmatrix}, C: \mathbb{R}^n \rightarrow \mathbb{R}^\ell$$

כי $z \in \mathbb{R}^n$ ויש לי ℓ אילוצים פעילים, $C_i: \mathbb{R}^n \rightarrow \mathbb{R}$. הנחנו בסיס אורתונורמלי וזה גורר $\ell = n$, כלומר $C: \mathbb{R}^n \rightarrow \mathbb{R}^n$. נחשב את היעקוביאן של C :

$$J_C(z) = \begin{pmatrix} \frac{\partial C_1}{\partial z_1} & \frac{\partial C_1}{\partial z_2} & \dots & \frac{\partial C_1}{\partial z_n} \\ \frac{\partial C_2}{\partial z_1} & \frac{\partial C_2}{\partial z_2} & \dots & \frac{\partial C_2}{\partial z_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial C_n}{\partial z_1} & \frac{\partial C_n}{\partial z_2} & \dots & \frac{\partial C_n}{\partial z_n} \end{pmatrix} = \begin{pmatrix} \nabla C_1(z)^T \\ \vdots \\ \nabla C_n(z)^T \end{pmatrix}$$

$$tJ_C(x)d = t \begin{pmatrix} \langle \nabla C_1(x), d \rangle \\ \vdots \\ \langle \nabla C_n(x), d \rangle \end{pmatrix}$$

מסקנה: \star בכתיב וקטורי:

$$C(z) - tJ_C(x)d = 0$$

השאלה: האם יש למשוואה זו פתרון?

נסמן

$$\underbrace{C(z) - tJ_C(x)d}_{R(z,t)} = 0$$

נשים \heartsuit :

$$1. R: \mathbb{R}^{n+1} \rightarrow \mathbb{R}^n$$

$$2. \frac{\partial R}{\partial z_i} = \frac{\partial C}{\partial z_i} \text{ כי } tJ_C(x)d \text{ לא תלוי ב-} z. \text{ מסקנה: } J_{R,z} = J_C \text{ כאשר } J_{R,z} \text{ מסמן רק נגזרות } \frac{\partial}{\partial z_i}.$$

$$3. J_{R,z}(x, 0) = J_C(x) = \begin{pmatrix} \nabla C_1(x)^T \\ \vdots \\ \nabla C_n(x)^T \end{pmatrix} \text{ שורות } J_C(x) \text{ בת"ל ולכן } J_C(x) \text{ הפיכה כלומר } J_{R,z} \text{ הפיכה.}$$

$$4. R(x, 0) = C(x) - 0 = C(x) = 0 \text{ כי שורות } C \text{ הם האילוצים הפעילים ב-} x.$$

מסקנה: לפי משפט הפונקציה הסתומה בסביבת $\begin{pmatrix} x \\ 0 \end{pmatrix}$ קיים פתרון יחיד למשוואה $R(z, t) = 0$ בפרט עבור $t = \frac{1}{k}$ קיים z_k כך ש- $z_k \rightarrow x$ וכן $(z_k, \frac{1}{k})$ פתרון.

בעיה: הנחנו $\{\nabla C_i\}$ אורתונורמלי אבל היה נתון רק בת"ל. אפשר רק $\{\nabla C_i\}$ בסיס? כלומר לא אורתו, אבל כן $\ell = n$ אילוצים פעילים. להוכיח ש- \star פתירה: אותו דבר בדיוק.

אבל הוכחנו גם ש- $d \rightarrow d_k \Rightarrow \langle \nabla C_i, d \rangle \Rightarrow \langle \nabla C_i, d_k \rangle$ על ידי שימוש באורתונורמליות.

תיקון 1: נוכיח את הנ"ל $d_k \rightarrow d \Rightarrow \langle \nabla C_i, d \rangle \Rightarrow \langle \nabla C_i, d_k \rangle$ בלי להשתמש באורתונורמליות. $\langle \nabla C_i, d_k \rangle = \nabla C_i^T d_k$ לכן

$$\begin{pmatrix} \langle \nabla C_1(x), d_k \rangle \\ \vdots \\ \langle \nabla C_n(x), d_k \rangle \end{pmatrix} = \begin{pmatrix} \nabla C_1(x)^T d_k \\ \vdots \\ \nabla C_n(x)^T d_k \end{pmatrix} = \begin{pmatrix} \nabla C_1(x)^T \\ \vdots \\ \nabla C_n(x)^T \end{pmatrix} d_k = J_C(x) d_k$$

מהנ"ל בכתיב וקטורי: $\langle \nabla C_i, d_k \rangle \rightarrow \langle \nabla C_i, d \rangle \iff J_C(x) d_k \rightarrow J_C(x) d \iff \langle \nabla C_i, d_k \rangle \rightarrow \langle \nabla C_i, d \rangle$ מהירות של $J_C(x)$ בסיס $J_C(x)$ הפיכה. כפל במטריצה = פונקציה הפיכה \Leftarrow

$$d_k = J_C^{-1}(J_C d_k) \rightarrow J_C^{-1}(J_C d) = d$$

בעיה: מה קורה כאשר $\{\nabla C_i\}$ רק בת"ל ולא בסיס? $\ell < n$. יש פחות אילוצים ש- z_k צריך לקיים, הבעיה אמורה להיות קלה יותר. קיבלנו $\langle \nabla C_i, d_k \rangle \rightarrow \langle \nabla C_i, d \rangle$ מפתרון \star :

$$\star \begin{cases} f_i(z) = t \langle \nabla f_i(x), d \rangle \\ h_j(z) = t \langle \nabla h_j(x), d \rangle \end{cases}$$

אז: ב- \star היו n משוואות. השתמשנו במשפט הפונקציה הסתומה למצוא פתרון יחיד עבור $t = \frac{1}{k}$ וקיבלנו n תוצאות ב- $\langle \nabla C_i, d \rangle \rightarrow \langle \nabla C_i, d_k \rangle$.

עכשיו: יש פחות משוואות, אמורים להיות ∞ פתרונות אבל עדיין נרצה n פעמים $\langle \nabla C_i, d \rangle \rightarrow \langle \nabla C_i, d_k \rangle$ בשביל ההמשך.

איך נפתור? נוסיף אילוצים מלאכותיים כדי ש- \star יחזור להיות מערכת משוואות עם n משוואות.

בסוף צריך $\{\nabla C_i\}$ יגדל להיות בסיס.

נשלים אותו: $\{\nabla C_i\} \cup \{y_{\ell+1}, \dots, y_n\}$. צריך למצוא אילוצים $C_{\ell+1}, \dots, C_n$ כך ש-

$$1. \nabla C_i = y_i$$

$$2. C_i(x) = 0$$

הכי פשוט: $C_i(z) = \langle y_i, z - x \rangle$. שימו \heartsuit ש-1, 2 מתקיימים (זוהי האילוף הלינארי היחיד שמקיים את זה).

האילוף הנוסף לבעיה: $C_i(z) = 0 \Leftarrow$ עכשיו נגדיר

$$C(z) = \begin{pmatrix} C_1(z) \\ \vdots \\ C_\ell(z) \\ \langle y_{\ell+1}, z - x \rangle \\ \vdots \\ \langle y_n, z - x \rangle \end{pmatrix}$$

$$J_C(x)d = \begin{pmatrix} \langle \nabla C_1(x), d_k \rangle \\ \vdots \\ \langle \nabla C_\ell(x), d_k \rangle \\ \langle y_{\ell+1}, d \rangle \\ \vdots \\ \langle y_n, d \rangle \end{pmatrix}$$

נכתוב משוואה:

$\star \star C(z) - tJ_C(x)d = 0 \iff \ell$ השורות הראשונות. מכאן והלאה בגלל ש- $\{\nabla C_i\} \cup \{y_{\ell+1}, \dots, y_n\}$ בסיס אפשר להשתמש בהוכחה המקורית:

ל- $\star \star$ פתרון יחיד עבור $t = \frac{1}{k}$, נסמנו (z_k, t_k) , בפרט הוא פותר את ℓ הראשונות, \star .
 $z_k \in M \Leftarrow$

בנוסף, מ- $\star \star$ נקבל

$$\begin{aligned} \langle \nabla C_i, d_k \rangle &\rightarrow \langle \nabla C_i, d \rangle \\ \langle y_i, d_k \rangle &\rightarrow \langle y_i, d \rangle \end{aligned}$$

ומכאן ההמשך כמו בהוכחה המקורית.

אמרנו: $\ell < n \Leftarrow$ אמורים להיות ל- \star אינסוף פתרונות $(z_k^1, \frac{1}{k}), (z_k^2, \frac{1}{k}), \dots$ איפה האינסוף? באפשרויות השלמה לבסיס. ■

מסקנה: אם תנאי LICQ מתקיימים ב- x^* או x^* מינימום מקומי $x^* \Leftarrow$ נקודת KKT.

תזכורת: דיברנו על משמעות גיאומטרית של KKT. אמרנו $-\nabla f = \sum_{i \in I} \lambda_i \nabla f_i$ כאשר $\nabla_x L = 0$ $\iff \lambda_i \geq 0$.

$$\text{נסמן } C = \left\{ \sum_{i \in I} \lambda_i \nabla f_i \mid \lambda_i \geq 0 \right\} \text{ החרוט הנפרש ע"י } C.$$

צ"ל: $F(x) = T_M(x)$ כאשר x מינימום מקומי. $-\nabla f \in C \iff \nabla_x L = 0$. כעת לפי הלמה של פארקש מתקיים $-\nabla f \in C$ (1).

או (מפריד)

(2) $-\nabla f$ ממש לא ב- C יש על מישור מפריד בין $-\nabla f$ לבין C . באופן מתמטי: קיים $d \in \mathbb{R}^n$ כך ש:

$$\langle d, -\nabla f \rangle > 0 \quad (\text{א})$$

$$\langle d, -\nabla f \rangle \leq 0 \quad \text{לכל } i \in I \quad (\text{ב})$$

אם x מינימום מקומי אז (2) לא אפשרי. (ב) $\Leftarrow d \in F(x) \Leftarrow d \in T_M(x)$ \star

\star הניחו שאין אילוצי h_j . זה עדיין יעבוד.

(א) $\langle d, -\nabla f \rangle > 0 \Leftarrow$ אבל הוכחנו $d \in T_M(x)$ כאשר x מינימום מקומי של f $\Leftarrow \langle d, -\nabla f \rangle \leq 0$.

מסקנה: $-\nabla f \in C$ (בהכרח (1)) $\Leftarrow \nabla_x L = 0$.

בבית: הוכיחו שבמקרה זה, כל שאר תנאי KKT מתקיימים.

הערה 6.28. אם יש h_j אז מגדירים את C אחרת, ללוקחים h_j בחשבון ומשתמשים בלמת פארקש האחרת.

חלק IV

אלגוריתמים לפתרון בעיות עם אילוצים.

הבעיה:

$$\begin{aligned} P : \min & f(x) \\ \text{s.t.} & f_i(x) \leq 0 \end{aligned}$$

נניח אין h_i כרגע.

ניקח השראה מלאגרנז': נוסיף את האילוצים לפונקציית המטרה:

$$Q : \min_{x \in \mathbb{R}^n} f(x) + \sum \beta(f_i(x))$$

הפעם: β היא פונקציית מחסום. נדרוש $\lim_{x \rightarrow 0^-} \beta(x) = \infty$ וכן $\beta(x) > 0$ לכל $x < 0$. כלומר β מענישה על קירבה לגבול שמגדיר כל אילוץ.

חפשו מינימום של Q בעזרת למשל שיטת ניוטון.

$$\arg \min Q \neq \arg \min P$$

כי Q לוקח בחשבון קנס על קרבה לשפה בעוד שאנחנו מחפשים P .

פתרון:

אלגוריתם 6.29. שיטת המחסום:

$$1. \text{נגדיר } \beta(t, x) = f(x) + t \sum \beta(f_i(x))$$

$$2. \text{מוצאים } x_t^* = \arg \min \beta(t, x)$$

$$3. \text{מקטינים את } t, \text{ למשל } t^* = \frac{1}{2}t$$

$$4. \text{משתמשים ב-} x_t^* \text{ כנקודת התחלה של שיטת ניוטון (למשל) כדי לפתור את } \min_{x \in \mathbb{R}} \beta(t^+, x)$$

$$5. \text{מסתכלים על } \lim_{t \rightarrow 0} x_t^*, \text{ כלומר מספר האיטרציות } \leftarrow \infty$$

$$\text{בדרי"כ נגדיר } \beta(x) = -\log(-x)$$

מתברר שהשיטה הזאת לא טובה.

בעיות:

$$(1) \text{אולי } \{x_{t_k}^*\} \text{ לא מתכנסת.}$$

פתרון: ניקח בתור ה- $\arg \min$ נקודת הצטברות של הסדרה.

אם הבעיה המקורית קמורה (f, f_i פונקציות קמורות) אז $B(t, x)$ קמור \Leftarrow יש לבעיה 1 פתרון יחיד. כאשר $t \rightarrow 0$ נקבל $B \rightarrow f$. אם יש רציפות במעבר מהבעיה (1) לבעיה המקורית אז נקבל כי הפתרון היחיד עבור $B(t, x)$ מתכנס עבור הפתרון האמיתי.

$$(2) \min B(t, x) \text{ קשה נומרית כאשר הפתרון של הבעיה האמיתית על שפת התחום האפשרי.}$$

נניח ש- $x^* \rightarrow x_k^* \rightarrow x^*$ על שפת התחום האפשרי, כלומר אחד האילוצים פעיל, בה"כ $f_1(x^*) = 0$. כדי למצוא $x_{t_k}^* = \arg \min B(t_k, x)$ משתמשים באלגוריתם מורד הגרדיאנט:

$$\nabla_x B(t, x) = \nabla f + \sum \beta'(f_i(x)) \nabla f_i = \nabla f + \sum -\frac{t}{f_i(x)} \nabla f_i$$

$$\text{אבל } 0 \rightarrow f_i(x_{t_k}^*) \rightarrow 0, t \rightarrow 0 \text{ לכן נומרית החל ממקום מסויים יהיה לי "0"} \text{ במחשב וזה לא בריא.}$$

$$\text{פתרון: ידוע שב-} x_t^* \text{ מתקיים } 0 = \nabla_x B(t, x) = \nabla f + \underbrace{\sum -\frac{t}{f_i} \nabla f_i}_{\lambda_i :=} \Leftarrow \nabla f(x_t^*) + \sum \lambda_i \nabla f_i = 0 \text{ ונשים } \heartsuit \text{ שמתקיים } t > 0 \text{ לפי ההגדרה וכן } f_i(x_t^*) < 0 \text{ כלומר } \lambda_i > 0.$$

מסקנה: ב- x_t^* מתקיים:

$$1. \nabla f + \sum \lambda_i \nabla f_i = 0$$

$$2. f_i < 0$$

$$3. \lambda_i > 0$$

$$4. \lambda_i f_i = -t$$

כלומר x_t^* כמעט נקודת KKT (זה היה בדיוק KKT אם אגף ימין ב-(4) היה 0 ולא $-t$). זה מביא אותנו לפיתוח אלגוריתם חדש שזוהא את שיטת המחסום:

אלגוריתם 6.30. אלגוריתם נקודת פנים primal-dual.

$$1. \text{מצאו (בקירוב) } x_t^* \text{ המקיים } 0 = \nabla f + \sum \lambda_i \nabla f_i = 0, f_i < 0, \lambda_i > 0, \lambda_i f_i = -t$$

$$2. \text{הקטינו את } t \text{ וחזרו ל-(1) גם } x_t^* \text{ כנק' התחלה.}$$

נשים \heartsuit :

$$1. x_t^* \text{ תמיד נק' אפשרית בבעיה המקורית (כי (2)).}$$

$$2. (x^*, \lambda_t^*) \text{ אפשרית ב-} WD \text{ (כי (1), (2), (3))} \Leftarrow V_{WD} \geq L(x^*, \lambda_t^*) \text{ אם } LD \text{ שקולה ל-} WD \text{ אז מפער הדואליות:}$$

$$\begin{aligned} 0 &\leq V_P - V_{LD} = V_P - V_{WD} \leq f(x_t^*) - L(x_t^*, \lambda_t^*) \\ &= f(x_t^*) - \left(f(x_t^*) + \sum \lambda_i^* f_i(x_t^*) \right) \\ &= - \sum \lambda_i^* f_i \\ &= - \sum -t \\ &= mt \end{aligned}$$

מהתוצאה הזאת אפשר לקבל הערכה לשגיאה: אם עוצרים כאשר $t < \varepsilon$, כמה אנחנו קרובים לפתרון?

$$(א) V_P \leq f(x_t^*)$$

(ב) ראינו: $f(x_t^*) - L = mt$, לכן

$$f(x_t^*) = L + mt \leq V_{WD} + mt \leq V_P + mt$$

$$V_P \leq f(x_t^*) \leq \underbrace{V_P + mt}_{\rightarrow V_P}$$

שאלות פתוחות (אצלנו):

1. איך מוצאים את (x_t^*, λ_t^*) ? אפשר לחפש בגוגל SQP ולגלות שמקרים את הבעיה המקורית בעזרת קירוב ריבועי ופותרים במדויק. חובה: קמירות.
2. מה עם h_i ? בגדול זה אותם אלגוריתמים אבל על משטחים. $h_i = 0$ מגדיר משטח ב- \mathbb{R}^n , קצת גא'ד...

חלק V

מטה היוריסטיקות.

איך פותרים את

$$\begin{aligned} \min f \\ \text{s.t. } f_i \leq 0 \\ h_i = 0 \end{aligned}$$

בלי לחשב ∇f . למה שנרצה לעשות את זה?

1. ייתכן שהקבוצה האפשרית בדידה. אין אינפי.
 2. ייתכן ש- f לא גזירה.
 3. לחשב ∇f יקר מדי: אופטימיזציה של היפר פרמטרים בלמידת מכונה (גודל המימד החבוי, מספר השכבות, קצב הלמידה...).
- הרעיון הוא לקחת השראה מהטבע. הטבע עושה אופטימיזציה בלי פרמטרים, ניקח ממנו השראה.
- למה מטה היוריסטיקות? כי אלה יהיו כלים כלליים שתופסים לגבי הרבה בעיות.

7 ריכוך מדומה - Simulated Annealing.

לוקחים השראה מפיזיקה סטטיסטית.

עובדות על מגנטים:

1. אטומי מתכת הם מגנטים קטנים.
2. כל אטום יכול להיות באחד משני מצבים בלבד: או שהוא נראה $-$ או שהוא נראה $+$, נסמן בהתאמה \downarrow וכן \uparrow .
3. אם מסדרים אטומים בשורה וכולם באותו מצב מקבלים מגנט גדול.
4. אם האטומים בשורה לא מסכימים על המצב- זה לא מגנט.
5. מגנטים לא אוהבים לא להסכים. $\uparrow\uparrow = \odot$, $\uparrow\downarrow = \ominus$.
6. לפעמים הדחייה לא מספיקה בשביל להפוך את הקוטביות של אחד מהם.
7. אם ניתן לאחד המגנטים במצב $\uparrow\downarrow$ דחיפה קלה הוא ישלים את העבודה לבד ויהפוך ל- $\uparrow\uparrow$ או ל- $\downarrow\downarrow$.

שאלה 7.1. איך יוצרים מגנט (בהינתן התצפיות שלי (1)-(7))?

1. מסדרים אטומים של מתכת בשורה באקראי $\uparrow\uparrow\downarrow\downarrow\uparrow\downarrow\downarrow\uparrow\uparrow$.
2. מחממים. כל האטומים מקבלים באקראי דחיפות קלות לכיוונים שונים. נראה מעברים כאלו: $\uparrow\downarrow \rightarrow \uparrow\uparrow$ כי המגנט למטה רוצה להסתובב והדחיפה עוזרת לו.
3. מחכים שהמצב יתייצב.
4. מורידים קצת את הטמפרטורה.
5. בסוף נשאר רק $\uparrow\uparrow\uparrow\uparrow\uparrow\uparrow\uparrow\uparrow\uparrow\uparrow$ (או רק $\downarrow\downarrow\downarrow\downarrow\downarrow\downarrow\downarrow\downarrow\downarrow\downarrow$).

מודל מתמטי:

1. האטומים יושבים על \mathbb{Z} (או תת קבוצה סופית).

2. בין כל 2 שכנים נגדיר אנרגיה: $\uparrow_i \uparrow_{i+1}$ או $\downarrow_i \downarrow_{i+1}$ אומר $E_i = -1$. $\uparrow_i \downarrow_{i+1}$ או $\downarrow_i \uparrow_{i+1}$ אומר $E_i = 1$. נסמן את הקונפיגורציה כולה ב- σ , לדוגמה

$$\sigma = (\dots, -1, 1, -, 1, 1, \dots) \iff \dots \downarrow_i \uparrow_{i+1} \downarrow_{i+1} \dots$$

3. נסכים את כל האנרגיות: זו האנרגיה של הקונפיגורציה $E(\sigma) = \sum_{i=-\infty}^{\infty} E_i = - \sum_{i=-\infty}^{\infty} \sigma_i \sigma_{i+1}$ (זה ההמילטוניאן \mathcal{H}).

4. הטבע שואף למזער את האנרגיה אבל הרעש האקראי (נובע מהחום) הורס לו. איזון בין 2 הכוחות מוביל לכך שהסיכוי לראות את σ אחרי התייצבות המערכת הוא לפי התפלגות בולצמן:

$$\mathbb{P}(\sigma) \propto e^{-\frac{E(\sigma)}{T}}$$

התפלגות בולצמן היא כמו התפלגות נורמלית- צצה בכל מיני מקומות.

נשים ♡:

1. אם $E(\sigma) \ll 0$ נמוכה אזי $\mathbb{P}(\sigma) \gg 0$ גבוהה.

2. אם $T \rightarrow \infty$ אזי $\mathbb{P}(\sigma) \propto 1$. כולם שווים: הדחיפות שמקבלים כל כך חזקות שהם תמיד יתהפכו.

3. אם $T \rightarrow 0$ אז $\mathbb{P}(\sigma) \propto \begin{cases} 1 & \sigma = \arg \min E(\sigma) \\ 0 & \text{else} \end{cases}$

איך אפשר להשתמש בכל הידע הזה כדי לפתור את בעיית הסוכן הנוסע?

נתאר מתמטית את המודל:

מסלול: בהינתן n ערים, כל מסלול הוא פרמוטציה של S_n (על כל n האיברים).

מקבלים מטריצת מרחקים

לעיר מעיר	1	2	...	n
1	0	1		
2	2			
⋮			etc	
n				

נגדיר d_{ij} להיות המרחק בין עיר i לעיר j . מחיר המבולל הוא $C(\pi) = \sum_i d_{\pi_i \pi_{i+1}}$ ניסוח בעיית אופטימיזציה:

$$\begin{aligned} \min C(\pi) \\ \text{s.t. } \pi \in S_n \end{aligned}$$

קבוצה אפשרית בדידה. איך מחשבים $\nabla C(\pi)$??

מצד שני, מרחב החיפוש סופי. אפשר לבדוק את כל האפשרויות. בעיה: יש המון אפשרויות, $n!$ אפשרויות.

אלגוריתם 7.2. פתרון בעזרת Simulated Annealing:

1. בוחרים π התחלתית באקראי ומתחילים עם T גדול.

2. מגרילים באקראי פרמוטציה שכנה: $\pi^+ = \pi \cdot (i, j)$. בעצם π^+ היא π רק שהעיר i החליפה את המקום שלה עם העיר j -ה.

3. אם $C(\pi^+) \leq C(\pi)$ שומרים את π^+ בתור האיטרציה הבאה וחוזרים איתה ל-(2).

4. אחרת $C(\pi^+) > C(\pi)$: מקבלים את π^+ בסיכוי $e^{-\frac{1}{T}(C(\pi^+) - C(\pi))}$ וחוזרים בחזרה ל-(2) עם π המקורי.

5. אחרי מספיק זמן, מקטינים קצת את הטמפרטורה T .

6. חוזרים על זה עד ∞ .

תוצאת תיאורטית: בהכרח התהליך יסתיים $\lim_{k \rightarrow \infty} \pi_k = \arg \min C$.

בעיה: צריך להוריד T לאט מאוד, אין תקציב לזה.

השוואה למפעל המגנטים:

1. זהה.

2. הייתי הולך לאטומים, רואה קונפיגורציה של $\uparrow\downarrow\uparrow\downarrow\uparrow\downarrow$, רואה את האטום של \uparrow ומנסה להפוך אותו כדי לראות אם הוא משפר אותי או לא.

3. סימולציה של העדפה של הטבע של שכנים עם אנרגיה נמוכה יותר כי ב-(2) כולם שווים. שכנים עם C נמוך יותר מתקבלים אוטומטית. שכנים עם C גבוה יותר: לא תמיד.

4. זהה ל-3.

5. זהה.

6. זהה.

מאחורי הקלעים: אנחנו בעצם דוגמים תהליך סטוכסטי:

$$\pi_0, \pi_1, \dots$$

כאשר π_0 הוא אקראי, נדגם מהתפלגות בולצמן $e^{-\frac{E(\pi)}{T}}$. כעת,

$$\mathbb{P}(\pi_{i+1} = k | \pi_i = j) = \begin{cases} 0 & k, j \text{ לא שכנות} \\ \frac{1}{\#j \text{ שכנים של } j} & k, j, E(k) \leq E(j) \\ \frac{1}{\#j \text{ שכנים של } j} e^{-\frac{\Delta E}{T}} & k, j, E(k) > E(j) \\ 1 - \frac{1}{\#j \text{ שכנים של } j} e^{-\frac{\Delta E}{T}} - \frac{1}{\#j \text{ שכנים של } j} & k = j \end{cases}$$

בעצם יש לנו שרשרת מרקוב.

משפט 7.3. אם:

1. אפשר להגיע מכל מצב i לכל מצב j תוך מספר סופי של צעדים. (אי פריקות).
2. איפשהו אפשר להישאר במקום $\mathbb{P}(\pi^+ = i | \pi = i) > 0$ עבור i כלשהו. (אי מחזוריות).
3. קיימת התפלגות \mathbb{Q} על כל המצבים כך ש-

$$\mathbb{P}(\pi_{i+1} = k | \pi_i = j) \mathbb{Q}(j) = \mathbb{P}(\pi_{i+1} = j | \pi_i = k) \mathbb{Q}(k)$$

(איזון מפורט).

הוכחה. אז:

$$\lim_{k \rightarrow \infty} \pi_k = \mathbb{Q}$$

נראה ש- $\alpha e^{-\frac{E(i)}{T}} \mathbb{Q}(i)$ מקיימת את תנאי (3) עם הסתברויות המעבר שבחרנו:

אם k, j לא שכנים, התנאי יתקיים אוטומטית.

נניח שכנים וכן $E(k) \leq E(j)$ אזי

$$\begin{aligned} \mathbb{P}(\pi_{i+1} = k | \pi_i = j) \mathbb{Q}(j) &= \frac{1}{\#j \text{ שכנים של } j} \frac{e^{-\frac{E(j)}{T}}}{\sum_j e^{-\frac{E(j)}{T}}} \\ \mathbb{P}(\pi_{i+1} = j | \pi_i = k) \mathbb{Q}(k) &= \frac{1}{\#j \text{ שכנים של } j} e^{-\frac{\Delta E}{T}} \frac{e^{-\frac{E(k)}{T}}}{\sum_j e^{-\frac{E(j)}{T}}} \\ &= \frac{1}{\#j \text{ שכנים של } j} \frac{e^{-\frac{E(k)}{T} - \frac{\Delta E}{T}}}{\sum_j e^{-\frac{E(j)}{T}}} \\ &= \frac{1}{\#j \text{ שכנים של } j} \frac{e^{-\frac{E(k)}{T} - \frac{(E(j) - E(k))}{T}}}{\sum_j e^{-\frac{E(j)}{T}}} \\ &= \frac{1}{\#j \text{ שכנים של } j} \frac{e^{-\frac{E(j)}{T}}}{\sum_j e^{-\frac{E(j)}{T}}} \\ &= \mathbb{P}(\pi_{i+1} = k | \pi_i = j) \mathbb{Q}(j) \end{aligned}$$

■ **כנדרש.**

מה צריך בשביל לכתוב אלגוריתם כללי שאפשר ליישם בכל בעיה, לא רק TSP ? (היוריסטיקה \leftarrow מטה היוריסטיקה).

1. פונקציית המטרה \leftarrow אנרגיה.

2. איך מגדירים שכן?

(א) שינוי מינימלי אפשרי.

(ב) במעבר שכן \leftarrow שכן \leftarrow שכן \leftarrow ... אפשר להגיע מכל מצב לכל מצב.

3. את שאר האלגוריתם אפשר להעציק מ- TSP .

צריך לקיים 3 דרישות של המשפט בדבר התכנסות שרשראות מרקוב:

1. אי פריקות: באמת (b) הנ"ל.

2. אי מחזוריות: אפשר להישאר במקום. בנוי אוטומטית באלגוריתם (המטבע יכול ליפול על 0).

3. איזון מפורט: בנוי בתוך ההסתברות שהמטבע יפול על 1.

בעיות אפשריות:

(1) איך בוחרים $0 < T \ll 1$ התחלתי? צריך לקחת בחשבון את הסקאלה של E .

כלל אצבע: לפני ריצת האלגוריתם אחרי שדגמנו x_0 אקראי: מסתכלים על הסביבה של x_0 ואוספים סטטיסטיקה על האנרגיה בסביבה ובחרים T_0 כך ש- $\mathbb{P}(i \rightarrow j) = e^{-\frac{\Delta E}{T}}$ לא תהיה קטנה מדי.

$$0.5 = e^{-\frac{E(\Delta E)}{T_0}}$$

פותרים עבור T_0 .

(2) מתי מורידים את T ? צריך בעדינות כדי לא להרוס את התכנסות השרשרת.

כלל אצבע: אחרי מספיק פעמים שקיבלנו את π^+ (למשל כל 1000 פעמים).

(3) בכמה להוריד את T ? תלוי ב- (2) : אם מחכים הרבה זמן אפשר להוריד בהרבה.

כלל אצבע: $T^+ = 0.9T$.

8 אלגוריתמים גנטיים.

8.1 מבוא לאבולוציה.

1. לפרטים (אנשים/ חיות) באבולוציה יש גנוטיפ: סדרה של אותיות $ACGTTTA...$

2. הגנוטיפ קובע את הפנוטיפ (תכונות שנראות לעין): גובה, צבע עיניים, מסת שריר, ...

ילד קטן $\rightarrow AATT$

איש שמן $\rightarrow ATAT$

3. פרטים באוכלוסיה עוברים סלקציה טבעית: פנוטיפ מתאים יותר לסביבה \Leftarrow סיכוי הישרדות והתרבות גבוהים יותר "החזק שורד".

4. פרטים מורשים לצאצאים שלהם את הגנוטיפ שלהם עם שינויים:

(א) מוטציה: שינוי קטן מקומי בגנוטיפ. למשל:

$$...ACGT \xrightarrow{SNP} AGGT...$$

או

$$...A\cancel{C}GT \xrightarrow{del} AGT...$$

או

$$...ACGT \xrightarrow{inv} TGGA...$$

(ב) רקומבינציה (שחלוף):

$$\begin{array}{c} AACGG \searrow \\ AAAAC \\ TTACC \nearrow \end{array}$$

הטבע עושה אופטימיזציה בלי לחשב ∇f , ניקח השראה.

דוגמה 8.1. בעיית התרמיל:

יש n פריטים עם מחיר C_i ושווי V_i . צריך לבחור מספר פריטים מהאוסף (יכול להיות 1, יכול להיות n) כך ש:

$$1. \sum_{i \text{ נבחר}} C_i < C \text{ כאשר } C \text{ זה תקציב נתון.}$$

$$2. \sum_{i \text{ נבחר}} V_i \text{ מקסימלי.}$$

ניסוח כבעיית אופטימיזציה:

נגדיר

$$Z_i = \begin{cases} 1 & i \text{ נבחר} \\ 0 & \text{else} \end{cases}$$

והבעיה תהיה

$$\begin{aligned} \max \quad & \sum_{i=1}^n V_i Z_i \\ \text{s.t.} \quad & \sum_{i=1}^n C_i Z_i < C \\ & Z_i \in \{0, 1\} \end{aligned}$$

אני יכול לנסות לפתור את זה בכוח ולמצוא את התרמיל עם הערך מבין המקסימלי, 2^n אפשרויות.

פתרון עם אלגוריתם גנטי:

צריך למצוא קידוד: פתרון לבעיה \iff גנוטיפ

גנוטיפ: $z_1 z_2 \dots z_n$.

אלגוריתם 8.2. אלגוריתם גנטי לפתרון בעיית התרמיל:

0. מצאו ייצוג של פתרון הבעיה: קידוד לגנוטיפ, למשל סדרה של משתנים בינאריים. חשבו: האם כל גנוטיפ מייצג פתרון חוקי? לא: אז צריך לחשוב איך מתקנים ייצוגים לא חוקיים בהמשך. מצאו פונקציית קשירות מתאימה. בבעיית max זו יכולה להיות פונקציית המטרה.

1. הגרילו אוכלוסייה אקראית של N גנוטיפים. גודל האוכלוסייה-היפר פרמטר.

2. חשבו את הכשירות של כל פרט (כשירות גבוהה \iff יותר סיכוי להתרבות). שווי התרמיל $= \sum_{i=1}^n V_i Z_i = f$ (תרמיל).

3. חזרו N פעמים:

(א) הגרילו זוג פריטים להתרבות. הסיכוי להתרבות מונוטוני עולה בכשירות: $\mathbb{P}(i) = \frac{f(i)}{\sum_{j=1}^n f(j)}$

(ב) צרו צאצא:

i. מוטציות: עושים $bit - flip$ לדוגמה $1011 \rightarrow 1001$.

ii. רקומבינציה: מגרילים אתר רקומבינציה, משמאל אבא ומימין אמא.

4. חוזרים ל-2) עם האוכלוסייה החדשה.

מה בעצם אנחנו מקבלים בסוף? רק גנוטיפים של 111...111 כי לא לקחנו בחשבון את האילוף.

בעיה: הקידוד יותר ייצוגים לא חוקיים.

פתרון 1: לשמור על חוקיות הפתרון לכל אורך הדרך.

1. מגרילים אוכלוסייה התחלתית חוקית.

2. דואגים שהאופרטורים הגנטיים (מוטציה/שחלוף) לא יצרו ייצוגים לא חוקיים.

למשל: לכבות ביטים באקראי בצאצא עד שמתקיים $\sum_{i=1}^n C_i Z_i < C$.

בעיה אפשרית בפתרון: לפעמי האופרטורים הגנטיים ייצרו ייצוג לא חוקי בסיכוי גבוה ואחרי התיקון (אולי יקר) הקשר בין ההורים לצאצא חלש.

פתרון 2: להעניש ייצוגים לא חוקיים עם כשירות נמוכה יותר למשל: $\sum_{i=1}^n V_i Z_i - t \sum_{i=1}^n C_i Z_i =$ שווי התרמיל.

בעיה: צריך לבחור t כדי שהעונש יהיה בדיוק בעוצמה הנכונה- לייצר באוכלוסייה הסופית הרבה חיידקים.

בעיה אפשרית:

כשירות שלילית \iff אי אפשר להגריל הורים להתרבות לפי $\frac{f(i)}{\sum_{j=1}^n f(j)}$ (זה כבר לא התפלגות).

פתרון 1: נגדיר $f^+(i) = f(i) + M$, נוסיף לכשירות קבוע מספיק גדול כדי שכולם יהיו חיוביים.

בעיה 1: לא תמיד יהיה קל למצוא M מספיק גדול.

בעיה 2: אם M גדול מדי לכולם סיכוי דומה להיבחר. רוצים סלקציה.

פתרון 2: נשנה את מנגנון הסלקציה:

אפשרות 1: לבחור באקראי 2 מתוך k הכשירים ביותר כאשר $k \ll N$.

אפשרות 2: סלקציית טורניר:

(1) מגרילים k מתוך N .

(2) המנצח: זה בעל הכשירות הגבוהה ביותר (בסיכוי גבוה). שני האחרונים יתרבו.

מתי עוצרים? בעבר: $\|\nabla f\| < \epsilon$, אבל עכשיו אין ∇f .

פתרונות:

1. נגמר התקציב- נניח מסיבה מסוימת יש לי רק שעה על המחשב להריץ את האלגוריתם- מה שיצא אני מרוצה.

2. אם חשוב להגיע לערך פונקציית מטרה C ומצליחים, לעצור.

3. כשהתהליך "התייצב", "מיצה את עצמו" וכו.

איך מזהים את זה?

מודדים לאורך הדרך את המגוון הגנטי. הרעיון: השחלוף יוצר פתרונות חדשים, משלב חלקים טובים מההורים ליצירת פתרונות טובים יותר. זה קורה כאשר שני ההורים מספיק שונים זה מזה. אם שני ההורים זהים, אין משמעות לשחלוף: הורים שהם 1110 ו-1110 יביאו לי ילד שהוא 1110. כשהמגוון נמוך- אפשר לעצור.

איך מודדים את המגוון הגנטי?

1. נמדוד $\mathbb{V}[f(x)]$ על האוכלוסייה הנוכחית.

2. נמדוד $\forall [x]$ לכל x פרט באוכלוסיה. בעיה: מוגדר רק עבור $x \in \mathbb{R}$, אי אפשר עבור ייצוגים "מתוחכמים".

בעיה: צריך לחשב בכל איטרציה, וזה יקר: $O(n^2)$.

פתרון: אפשר להשתמש במדדי שונות זולים יותר.

הבעיה הכי גדולה באלגוריתמים אלו: התכנסות מוקדמת: פרט אחד משתלט תוך מספר קצר של דורות. ברגע שזה קרה- האלגוריתם עוצר אפילו אם הפרט הוא לא הפתרון הכי טוב.

איך מזהים? מסתכלים על השונות של האוכלוסיה. אם השונות יורדת מהר מדי- בעיה. גם אם פונקציית המטרה עולה לאט מדי- בעיה.

איך פותרים? (1) מריצים כמה אוכלוסיות קטנות בנפרד זו מזו ופעם בכמה דורות מערבבים.

(2) להתאים היפר פרמטרים: להוריד את לחץ הסלקציה: לעלות את הסיכוי להתרבות על פרטים פחות כשירים.

(ב) להגדיר את המגוון הנוצר בהתרבות: למשל לעלות את הסיכוי למוטציות.

דוגמה 8.3. דוגמאות בסיסיות:

1. אופטימיזציה קלאסית: $\min_{x \in \mathbb{R}^n} f(x)$. ייצוג: $x \in \mathbb{R}^n$ - הווקטור הוא הייצוג. אופרטורים: מוטציה: $y = x + \varepsilon$ כאשר $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$.

שחלוף: מקבלים x, y , נחזיר z שמשלב ביניהם: למשל $z = \frac{x+y}{2}$. אם דטרמיניסטי מדי: מגרילים $\lambda \sim U[0, 1]$ ואז עושים $z = \lambda x + (1-\lambda)y$. שאלה למחשבה: מה עושים אם יש אילוצים בבעיה? כשירות: צריך להפוך בעיית \min לבעיית \max כי כשירות גבוהה \Leftarrow סיכוי גבוה להתרבות

2. בעיית הסוכן הנוסע. ייצוג: 1,3,5,6,7,2,4 כלומר תמורות על הערים שלי. מוטציה: החלפה של שני ערים במסלול. שחלוף: לקחת חצי מהערים מההתחלה של האבא וחצי מהסוף של האמה. בעיה: נוצרים בשחלוף ייצוגים לא חוקיים. פתרון: כל עיר שלא מופיעה/ מופיעה פעמיים אני אעניש- אולי אוריד נקודה.

3. רגרסיה סימבולית: נתונים דגימות x ותוויות y לכל x , מחפשים פונקציה $f(x)$ שתאים $f(x_i) = y_i$ הכי טוב. $f = \arg \min_{f \in A} \sum_{i=1}^n \|f(x_i) - y_i\|^2$ כאשר A היא קבוצת כל הפונקציות שאפשר למצוא על ידי הרכבה של $\sin, \cos, \exp, \ln, +, -, \cdot, /$ וכו'. צריך לבדוק, האם $f(x) = \sin(e^x) + \ln(x)$

האם זה $f(x) = \sin(x) \cos(x) + 10$. הסביבה A גדולה- כל כך גדולה שאני לא יודע להגדיר טופולוגיה על A , ולכן אין גרדיאנטים וכל מה שאנחנו רגילים אליו. פתרון: אלגוריתם גנטי. ייצוג: עץ חישוב:

$$\begin{array}{c} \sin \quad \rightarrow + \quad \leftarrow \quad \ln \\ \uparrow \quad \quad \quad \uparrow \\ \sin(e^x) + \ln(x) = \exp \quad \quad x \\ \uparrow \\ x \end{array}$$

או לדוגמה

$$\begin{array}{c} \cdot \quad \rightarrow + \quad \leftarrow \quad 10 \\ \nearrow \quad \nwarrow \\ \cos(x) \sin(x) + 10 = \cos \quad \sin \\ \uparrow \quad \quad \uparrow \\ x \quad \quad x \end{array}$$

מוטציה: רעיון 1: להחליף את אחד הצמתים בעץ בפונקציה אקראית אחרת. יכול לייצר ייצודים לא חוקיים $\cos(+)$. רעיון 2: ללכת לצומת יחסית נמוך בעץ ומגרילים את תת העץ מחדש. שחלוף: לחתוך תת עץ מכל הורה ולחבר אותם.

8.2 משפט הסכמה של הולנד (החוקר, לא המדינה).

הנחות:

1. מריצים אלגוריתם גנטי עם ייצוג בינארי: יש ℓ ביטים $z_1 z_2 \dots z_\ell$.
2. כל ביט עובר מוטציה בסיכוי p_m . באופן בלתי תלוי בביטים האחרים.
3. מבצעים שחלוף חד נקודתי בסיכוי p_c . אתר החיתוך נבחר באקראי: בסיכוי $1 - p_c$ אין רקומבינציה ובסיכוי p_c נבחר באקראי איפה לעשות רקומבינציה.

4. הורים נבחרים לפי $\frac{f_i}{\sum f_j}$.

סכמה: תת קבוצה של מרחב החיפוש המסכימה על ביטים נתונים.

למשל: סכמה $1 * 1$, נציגים: 1001, 1011, 1101, 1111.

משפט 8.4. משפט הסכמה: סכמות לא ארוכות מדי ושלו קובעות יותר מדי ביטים יגדלו במספר הנציגים באוכלוסיה אם הכשירות של הסכמה מספיק גבוהה.

נדייק: הגדרות:

$O(H)$ סדר הסכמה = מספר הביטים שהסכמה קובעת. לדוגמה:

$$O(1 * 1) = 2, O(* * 1) = 1$$

- $d(H)$ אורך הסכמה = המרחק בין הביט הראשון של H קובעת לאחרון (=מספר הרווחים שבה יכולה להתבצע רקומבינציה שתהרוס את הסכמה). לדוגמה:

$$d(1 * * 1) = 3, d(11 * *) = 1$$

- $u(H) = \mathbb{E}[f(H)]$: (נציג של $f(H)$) התוחלת מחושבת על כל הנציגים האפשריים (גם כאלו שאין כרגע באוכלוסיה).
- $\bar{f}(t)$: הכשירות הממוצעת בדור t .
- $m(H, t)$: מספר הנציגים של הסכמה H שנמצאים באוכלוסיה שנמצאים באוכלוסיה בדור t .
- $u(H, t)$: ממוצע הכשירות של הנציגים של H בדור t , הוא שווה ל- $\frac{f_i}{m}$ על $x_i^t \in H$.

משפט 8.5. משפט הסכמה, מדויק יותר :

$$\mathbb{E}[m(H, t+1)] \geq \frac{u(H, t)}{\bar{f}(t)} \cdot m(H, t) \cdot \left(1 - p_c \frac{d(H)}{\ell - 1}\right) \cdot (1 - p_m)^{O(H)}$$

כלומר בעברית :

$$\underbrace{\mathbb{E}[m(H, t+1)]}_{\text{תוחלת מספר הנציגים של } H \text{ בדור הבא}} \geq \underbrace{\frac{u(H, t)}{\bar{f}(t)}}_{\substack{\text{כשירות } H \text{ ביחס} \\ \text{לאוכלוסיה} \\ \text{:= (1)}}} \cdot m(H, t) \cdot \underbrace{\left(1 - p_c \frac{d(H)}{\ell - 1}\right)}_{\substack{\text{סיכוי שרקומבינציה} \\ \text{תחתוך בתור } H \\ \text{:= (2)}}} \cdot \underbrace{(1 - p_m)^{O(H)}}_{\substack{\text{הסיכוי שלא תהיה} \\ \text{מוטציה שתהרוס את } H \\ \text{:= (3)}}}$$

ואם ניקח את משפט הסכמה המקורי נוכל לתרגם אותו כך : סכמות (2) (3) יגדלו במספר הנציגים באוכלוסיה (1).
מסקנה : אם המקדם של $m(H, t)$ גדול מ-1 בא"ש הנ"ל, בממוצע, $m(H, t+1)$ יהיה גדול עוד יותר.
מתי המקדם גדל?

1. $\bar{f}(t) << u(H, t)$ (תורמת לכשירות הפרטים)
2. $d(H)$ קטן.
3. $O(H)$ קטן.

הוכחה. נסמן את הפרט i -ה באוכלוסיה בדור t ב- x_i^t .

אם אין מוטציה / רקומבינציה (מגרילים באקראי עם החזרה N פריטים מהדור הקודם : הסיכוי של x_i^t להיבחר בהגרלה נתונה הוא $\frac{f(x_i^t)}{\sum_{i=1}^n f(x_i^t)}$ אז

$$\begin{aligned} \mathbb{P}(x_i^{t+1} \in H) &= \mathbb{P}(x_i^{t+1} \text{ של ההורה } \in H) \\ &= \mathbb{P}(i \text{ נבחר להתרבות בהגרלה ה-} i) \\ &= \frac{1}{\sum_{i=1}^n f(x_i^t)} \cdot \left(\sum_{x_i^t \in H} f(x_i^t) \right) \\ &= \frac{1}{\bar{f}(t) \cdot N} (u(H, t) \cdot m(H, t)) \end{aligned}$$

כעת,

$$\begin{aligned} \mathbb{E}[m(H, t+1)] &= \mathbb{E}\left[\sum_{i=1}^N 1(x_i^{t+1} \in H)\right] \\ &= \sum_{i=1}^N \mathbb{E}[1(x_i^{t+1} \in H)] \\ &= \sum_{i=1}^N \mathbb{P}(x_i^{t+1} \in H) \\ &= N \cdot \frac{1}{\bar{f}(t) \cdot N} (u(H, t) \cdot m(H, t)) \\ &= \frac{u(H, t)}{\bar{f}(t)} m(H, t) \end{aligned}$$

כלומר הוכחנו למקרה ש- $p_c, p_m = 0$ וקיבלנו שיויון.

נניח שיש רק מוטציה: $p_m > 0, p_c = 0$, שוב,

$$\begin{aligned} \mathbb{P}(x_i^{t+1} \in H) &= \underbrace{\mathbb{P}(H \text{ ההורה של } x_i^{t+1} \text{ וגם המוטציה לא הרסה את } H)}_{:=A} + \underbrace{\mathbb{P}(H \text{ מוטציה הכניסה ל-} H)}_{\times} \\ &\geq \mathbb{P}(A) \\ &= \underbrace{\frac{u(H, t) \cdot m(H, t)}{\bar{f}(t) \cdot N}}_{\text{כמו מקודם, ההסתברות שההורה ב-} H} \cdot \underbrace{(1 - p_m)}_{\text{אין מוטציה בבית הראשון שהסכמה קובעת}} \cdot \underbrace{(1 - p_m)}_{\text{אין מוטציה בבית השני שהסכמה קובעת}} \cdots \underbrace{(1 - p_m)}_{\text{אין מוטציה בבית האחרון שהסכמה קובעת}} \\ &= \frac{u(H, t) \cdot m(H, t)}{\bar{f}(t) \cdot N} (1 - p_m)^{O(H)} \end{aligned}$$

ומכאן קל להוכיח.

אם $p_c, p_m > 0$

$$\begin{aligned} \mathbb{P}(x_i^{t+1} \in H) &= \underbrace{\mathbb{P}\left(\begin{array}{l} \text{אם היה השחלוף התרחש מחוץ לביטים ש-} H \\ \text{קובעת הצאצא קיבל את החלק הזה בגנום מהורה} \\ \text{שהיה נציג של } H \text{ והמוטציה לא הרסה} \end{array}\right)}_{:=A} + \underbrace{\mathbb{P}\left(\begin{array}{l} \text{רקומבינציה בתוך הסכמה} \\ \text{שיוצרת נציג של } H \end{array}\right)}_{\times} \\ &\geq \mathbb{P}(A) \\ &= \underbrace{\frac{u(H, t) \cdot m(H, t)}{\bar{f}(t) \cdot N}}_{\text{כמו מקודם}} (1 - p_m)^{O(H)} \cdot \underbrace{\mathbb{P}\left(\begin{array}{l} \text{רקומבינציה שלא חותכת בתוך הסכמה} \\ + \\ \text{אין רקומבינציה} \end{array}\right)}_{:=B} \end{aligned}$$

וכן

$$\mathbb{P}(B) = 1 - \mathbb{P}(H \text{ רקומבינציה חותכת}) = 1 - p_c \cdot \frac{d(H)}{\ell - 1}$$

ולכן

$$\mathbb{P}(x_i^{t+1} \in H) = \frac{u(H, t) \cdot m(H, t)}{\bar{f}(t) \cdot N} (1 - p_m)^{O(H)} \left(1 - p_c \cdot \frac{d(H)}{\ell - 1}\right)$$

ואז ממשיכים עם האינדוקטורים כמו שעשינו. ■

מסקנה שהיינו רוצים: ידוע כי

$$\mathbb{E}[m(H, t + 1)] \geq C \cdot m(H, t)$$

והיינו רוצים להכליל את זה ולומר

$$\mathbb{E}[m(H, t + 1)] \geq C \cdot m(H, t) \geq C^2 \cdot m(H, t - 1) \geq \cdots C^t \cdot m(H, 1)$$

וזה יתן לנו שסכמות טובות גדלות באוכלוסיה באופן מעריכי.

זה לא נכון: C משתנה מדור לדור ותלוי באוכלוסיה הנוכחית. בעיות נוספות:

1. ההוכחה היא למרות האופרטורים הגנטיים. הטענה הרווחת היא שהאופרטורים תורמים להצלחת האלגוריתם.
2. התוצאה נכונה רק בתוחלת. כהחלט ייתכנו ריצות של האלגוריתם בהן $m(H, t + 1) < C \cdot m(H, t)$. המשפט נכון כאשר מריצים ∞ פעמים את יצירת הדור ה- $t + 1$ או שהאוכלוסיה אינסופית.
3. עובד רק על ייצוג בינארי.

9 אסטרטגיות אבולוציה.

ההבדל העיקרי: אסטרטגיות אבולוציה פועלות לפי כללים דטרמיניסטים.

9.1 אלגוריתם CMA-ES.

הבעיה:

$$\min_{x \in \mathbb{R}^n} f(x)$$

כאשר x רציף ואין אילוצים. אפשר להוסיף אילוצים בדומה למה שעשינו עם ריכוך מדומה.

תיאור השיטה: שומרים בזיכרון התפלגות נורמלית n מימדית $\mathcal{N}(M, C)$ $\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \sim \mathcal{N}(M, C)$ כאשר $M \approx \arg \min f$ וכן

$$C_{ij} = \text{cov}(x_i, x_j)$$

אלגוריתם 9.1 CMA-ES.

1. דוגמים $x^1, x^2, \dots, x^N \sim \mathcal{N}(M, C)$ באופן בלתי תלוי (ניצירת האוכלוסייה).

2. ממיינים: $f(x^1) \leq f(x^2) \leq \dots \leq f(x^N)$.

3. משתמשים ב- $N-k$ הכי טובים כדי לעדכן את M, C :

$$M = \sum_{i=1}^k \frac{x^i}{k}$$

או

$$M = \frac{\sum_{i=1}^k \frac{x^i}{i}}{\sum_{i=1}^k \frac{1}{i}}$$

וכן

$$C_{ij} = \text{cov}(x_i, x_j) \approx \frac{1}{k-1} \sum_{\ell=1}^k (x_i^\ell - M_i)(x_j^\ell - M_j)$$

4. חוזרים ל-(1).

מתי עוצרים? למשל כאשר כל הדגימות x^1, \dots, x^N קרובים מאוד זה לזה.

בעיות ופתרונות: במציאות האלגוריתם קצת יותר מורכב:

1. משתמשים בממוצע רץ כדי לשמור על יציבות:

$$M^+ = \lambda M + (1 - \lambda) \sum_{i=1}^k \frac{x^i}{k}$$

(דומה למומנטום) עבור $0 < \lambda < 1$ קבוע.

2. כדי לאמוד את C צריך בו זמנית את כל המשולש העליון (היא סימטרית): $\frac{n^2+n}{2}$ פרמטרים. במקום לחשב C מחדש, עושים עדכון ממימד נמוך של C הקודמת (דומה ל-BFGS). כדי לאמוד את רכיב העדכון צריך רק k פרמטרים (או פחות) וזה כבר זול.

3. רוצים שהאלגוריתם ישלוט בקצב התנועה שלו. פתרון: ρ הקורולציה של כיוון התנועה. מודדים ρ ומקטינים את רכיבי המטריצה C כדי להביא את ρ ל-0 (מטריצה C עם ע"ע גדולים \iff גודל צעד גדול).

תוצאות תיאורטיות:

1. אם f ריבועית אז C קשורה באופן הדוק ל- H_f .

2. גיאומטריה של אינפורמציה: בעולם חדש זה בעצם מורד הגראדיאנט על משהו.