

הסקה סטטיסטית סיכום תרגולים - יואל אשכנזי

תומלל על ידי רגב יחזקאל אימרה

July 9, 2024

1 תרגול 1.

1.1 חזרה על הסתברות:

יהי X משתנה מקרי.

התוחלת של X הינה $\mathbb{E}[X] = \begin{cases} \sum P(x)x & \text{בדיד} \\ \int P(x)xdx & \text{רציף} \end{cases}$, שזה מעיין ממוצע משוכלל של ההתפלגות.

השונות של X הינה $var(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}^2[X]$, שזה מודד לי כמה אני רחוק ממרכז ההתפלגות.
השונות המשותפת של שני משתנים מקריים X ו- Y הינה $cov(X, Y) = \mathbb{E}_{XY} - \mathbb{E}_X \mathbb{E}_Y$ שנועד למדוד לי עד כמה X ו- Y לא מתואמים.

משפט (חוק השונות השלמה): בהינתן M^2 X, Y ונתון $var(Y) = \mathbb{E}[var[Y|X]] + var(\mathbb{E}[Y|X])$.

קישור להוכחה: הוכחה

דוגמא: על יד חישוב מהיר וישיר נגלה כי השונות של משתנה מקרי אקספוננציאלי היא $\frac{1}{\lambda^2}$.

דוגמא: $X \sim Exp(1), Y \sim Pois(X)$ נחשב את השונות של Y בעזרת חוק השונות השלמה:

$$var(Y) = \mathbb{E}[var[Y|X]] + var(\mathbb{E}[Y|X]) = \mathbb{E}[X] + var[X] + \frac{1}{1} + \frac{1}{1^2} = 2$$

פונקציה יוצרת מומנטים של X היא $M(t) = \mathbb{E}[e^{tX}]$.

דוגמא: נתון $X \sim Pois(\lambda)$, נחשב פונקציה יוצרת מומנטים:

$$M(t) = \mathbb{E}[e^{tX}] = \sum_{k=0}^{\infty} e^{kt} \frac{e^{-\lambda} \lambda^k}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} e^{kt} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda e^t}$$

דוגמא: $X \sim Geo(p)$, נחשב פונקציה יוצרת מומנטים:

$$\begin{aligned} M(t) &= \mathbb{E}[e^{tX}] = \sum_{k=1}^{\infty} e^{kt} (1-p)^{k-1} p = \sum_{k=1}^{\infty} e^{kt} (1-p)^{k-1} p \underbrace{=}_{{k \mapsto k+1}} p \sum_{k=0}^{\infty} e^{t(k+1)} (1-p)^k \\ &= pe^t \sum_{k=0}^{\infty} (e^t(1-p))^k \stackrel{*}{=} \frac{pe^t}{1 - (1-p)e^t} \end{aligned}$$

*: הטור הנ"ל מתכנס $\iff t < \ln\left(\frac{1}{1-p}\right)$ מתקיים

התפלגות רב נורמלית: כמו שאפשר לומר $X \sim N(\mu, \sigma^2)$, נגדיר וקטור של משתנים מקריים $\vec{X} \sim N(\vec{\mu}, \Sigma)$.

נאמר שהוקטור \vec{X} מתפלג נורמלית אם כל רכיב שלו מתפלג נורמלית.

מיהי \sum ? זו מטריצה שהרכיב ij שלו זה $cov(X_i, X_j)$.

זה סוף התרגול, לכן עכשיו נלך לישון שמחים ומאושרים.

2 תרגול 2.

2.1 פונקציה יוצרת קומולנטים.

פונקציה יוצרת קומולנטים היא $K_X(t) = \ln(M_X(t))$ תכונות של פונקציה יוצרת מומנטים:

$$1. e^{bt} M_X(at) = M_{aX+b}(t)$$

$$2. \text{ אם } X, Y \text{ בלתי תלויים: } M_{X+Y}(t) = M_X(t)M_Y(t)$$

תרגיל: יש לנו משתנה מקרי $X \sim \chi^2_{(k)}$ כאשר $P_x = \frac{1}{2^{\frac{k}{2}} \Gamma(\frac{k}{2})} x^{\frac{k}{2}-1} e^{-\frac{x}{2}}$ מהי הפונקציה יוצרת קומולנטים K_x ? פתרון:

$$\begin{aligned} M_X(t) &= \mathbb{E}[e^{tX}] = \int_0^\infty e^{tx} \frac{1}{2^{\frac{k}{2}} \Gamma(\frac{k}{2})} x^{\frac{k}{2}-1} e^{-\frac{x}{2}} dx = \frac{1}{2^{\frac{k}{2}} \Gamma(\frac{k}{2})} \int_0^\infty e^{tx} x^{\frac{k}{2}-1} e^{-\frac{x}{2}} dx = \frac{1}{2^{\frac{k}{2}} \Gamma(\frac{k}{2})} \int_0^\infty e^{-(\frac{1}{2}-t)x} x^{\frac{k}{2}-1} dx \\ &\stackrel{(*)}{=} \frac{1}{2^{\frac{k}{2}} \Gamma(\frac{k}{2})} \int_0^\infty \left(\frac{u}{\frac{1}{2}-t}\right)^{\frac{k}{2}-1} \cdot e^{-u} \cdot \frac{du}{\frac{1}{2}-t} = \frac{1}{2^{\frac{k}{2}} \Gamma(\frac{k}{2})} \frac{1}{(\frac{1}{2}-t)^{\frac{k}{2}}} \int_0^\infty u^{\frac{k}{2}-1} \cdot e^{-u} du = \frac{\Gamma(\frac{k}{2})}{2^{\frac{k}{2}} \Gamma(\frac{k}{2}) (\frac{1}{2}-t)^{\frac{k}{2}}} \\ &= \frac{1}{2^{\frac{k}{2}} (\frac{1}{2}-t)^{\frac{k}{2}}} = (1-2t)^{-\frac{k}{2}} \end{aligned}$$

ולכן אחרי הוצאת \ln על הפונקציה יוצרת מומנטים נקבל

$$K_x(t) = -\frac{k}{2} \ln(1-2t)$$

$$\begin{aligned} \star: \text{ נציב } u &= x \cdot (\frac{1}{2}-t) \Rightarrow du = (\frac{1}{2}-t)dx \\ \star\star: \int_0^\infty x^{a-1} e^{-x} dx &= \Gamma(a) \end{aligned}$$

2.2 במסגרת משפט הגבול המרכזי:

אנחנו יכולים לקרב משתנה בינומי לנורמלי: מתקיים

$$X \sim \text{Bin}(n, p) \xrightarrow{n \rightarrow \infty} \hat{X} \sim \mathcal{N}(np, np(1-p))$$

משפט ניימר פישר:

אם יש לי דגימות $\{x_i\}$ שהם $i.i.d$ אזי אומד $T\{x_i\}$ הוא אומד מספיק \iff ההתפלגות של המדגם ניתנת לפירוק, כלומר $P(\{x_i\}) = h(\{x_i\}) \cdot g(T, \theta)$.

דוגמה: נניח יש לי מ"מ $x_i \sim U[0, \theta]$ ונגדיר את האומד שלנו $T = \max_i x_i$ ולכן $p(x_i) = \frac{1}{\theta} \cdot 1_{[0, \theta]}$ כאשר $1_{[0, \theta]} = \begin{cases} 1 & 1 \in [0, \theta] \\ 0 & \text{else} \end{cases}$

$$P(x_i|T) = \frac{1}{\theta^n} \prod_{i=1}^n 1_{[0, T]} \stackrel{*}{=} \frac{1}{\theta^n} = \frac{1}{\theta^n} \prod_{i=1}^n 1_{[0, \theta]}$$

שזה שווה בדיוק להתפלגות המקורית, בגלל ש- T הוא הערך המקסימלי שהגרלנו, ולכן כל האינדיקטורים אכן מתקיימים בשני המקרים, כלומר אם יש T אין צורך ב- θ .

\star : מכיוון ש- $T = \max_i x_i$ בגלל ש- T מתקיים אז בוודאי θ מתקיים ולכן במקרה שלנו כל האינדיקטורים שווים ל-1 ולכן סה"כ נקבל שוויון. זה סוף התרגול, לכן עכשיו נלך לישון שמחים ומאושרים.

3. תרגול 3.

3.1 המשפחה האקספוננציאלית:

נאמר שהתפלגות $f_\theta(x)$ היא במשפחה אקספוננציאלית אם מתקיים

$$f_\theta(x) = h(x) \cdot e^{g(\theta)^T T - A(\theta)}$$

יתרון אחד הוא שבמקרה שניתן להציג את $f_\theta(x)$ ככה, מובטח לנו כי T יהיה אומד מספיק.
דוגמה:

1. $x \sim \mathcal{N}(\mu, \sigma^2)$, נבדוק האם התפלגות נורמלית היא חלק ממשפחה אקספוננציאלית:

$$\begin{aligned} P(x) &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x}{\sigma}\right)^2} \cdot e^{\frac{x}{\sigma} \cdot \frac{\mu}{\sigma} - \frac{1}{2} \frac{\mu^2}{\sigma^2}} \\ h(x) &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x}{\sigma}\right)^2} \\ T(x) &= \frac{x}{\sigma} \\ g(\theta) &= \frac{\mu}{\sigma} \\ A(\mu) &= \frac{\mu^2}{2\sigma^2} \end{aligned}$$

ולכן זה חלק ממשפחה אקספוננציאלית.

2. $x \sim \text{Bin}(n, p)$ התפלגות בינומית עם מספר קבוע של ניסיונות:

$$\begin{aligned} p(x) &= \binom{n}{x} p^x (1-p)^{n-x} = \binom{n}{x} \left(\frac{p}{1-p}\right)^x (1-p)^n = \binom{n}{x} e^{x \ln\left(\frac{p}{1-p}\right) + n \cdot (1-p)} \\ h(x) &= \binom{n}{x} \\ T(x) &= x \\ g(\theta) &= \ln\left(\frac{p}{1-p}\right) \\ A(\mu) &= -n \cdot (1-p) \end{aligned}$$

3.2 פריור / פוסטריור:

נניח ויש לי מטבע ואני רוצה להחליט כמה הוא הוגן, בשביל זה הטלתי אותו 100 פעמים 650 מההטלות שלי נחתו על H . ניחוש טוב יהיה $p = 0.35$. אבל! לפעמים יש פעמים שבהם ההטלה שלי סתם יצאה מוזרה; יכול להיות שלפני שהטלתי 100 פעמים את המטבע שלי הטלתי אותו עוד 50 פעמים רק שהפעם יצא לי 40 פעמים H , וברור שכעת $p \neq 0.35$. כאן נכנס לתמונה הפריור שלי, שבעצם מתחיל לי את הניסוי עם האמונות שלי לגבי איך שהפרמטרים מתנהגים. דוגמה: בניסוי שלנו, נוכל לומר כי $X \sim \text{Bin}(100, p)$ ואנחנו ממחפשים את p . בשביל זה נשתמש בהתפלגות בטא:

$$p \sim B(a = 10, b = 40)$$

זה בעצם אומר שאני מאמין שב50 הטלות מטבע, יצא לי 40 H .
לכן, נוכל לחשב את הפוסטריור לפי הנוסחה

$$\text{posterior} = p(\{x_i\}|\theta) \cdot \frac{p(\theta)}{p(\{x_i\})}$$

כאשר $p(\{x_i\}|\theta)$ זה הנראות של הדגימות, $p(\theta)$ זה הפריור.

3.2.1 התפלגויות צמודות:

שתי התפלגויות צמודות אם

$$\{x_i\} \sim f(x|\theta), \theta \sim f(a)$$

דוגמה: $x = x_i \sim \text{Pois}(\lambda), \lambda \sim \Gamma(a, b)$

$$p(\lambda|x) = p(x|\lambda) \frac{p(\lambda)}{p(x)} = C \cdot e^{-n\lambda} \cdot \lambda^{\sum_{i=1}^n x_i} \cdot C^*(\lambda^{a-1} \cdot e^{-b\lambda}) = \tilde{C} e^{-((n+b)\lambda)} \lambda^{a+\sum_{i=1}^n x_i - 1} \sim \Gamma(a + \sum_{i=1}^n x_i, n + b)$$

3.2.2 שיטת המומנטים:

בהינתן אוסף דגימות $\{x_i\}$, נרצה להעריך פרמטר מסויים θ בעזרת המומנטים של הדגימות שלנו.
דוגמה: $\{x_i\} \sim U[a, b]$ ונחשב את המומנטים שלנו:

$$M_1 = \mathbb{E}[x] = \frac{1}{2}(a + b), M_2 = \mathbb{E}[x^2] = \frac{1}{12}(b - a)^2$$

נתפור את המשוואות הנ"ל עבור a, b ונקבל

$$a = -\frac{12M_2}{8M_1}, b = 2M_1 + \frac{12M_2}{8M_1}$$

$$\text{כאשר } M_1 = \sum_i \frac{x_i}{n}, M_2 = \sum_i \frac{x_i^2}{n}$$

3.2.3 אומד נראות מקסימלי ומיקסום הפוסטריור:

ההוראות:

1. נחשב את הפוסטריור $p(\theta|x)$

2. נוציא לזה לוג

3. נמצא נקודות קיצון

4. נראה שזה נקודת מקסימום

דוגמה: $x = x_i \sim \text{Pois}(\lambda), \lambda \sim \Gamma(a, b)$: נחשב אומד נראות מקסימלי $\hat{\lambda}$ ואז נמקסם את הפוסטריור $\tilde{\lambda}$:

$$L(x) = \prod_{i=1}^n p(x_i|\lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i} = \lambda^n e^{-\lambda \sum x_i}$$

$$\log(L(x)) = n \ln \lambda - \lambda \sum x_i$$

$$\frac{d}{d\lambda} \log(L(x)) \hat{\lambda} = \frac{n}{\lambda} - \sum x_i = 0 \Rightarrow \frac{n}{\sum x_i}$$

ולפי הנגזרת השנייה נראה שזה מקסימום:

$$\frac{d^2}{d\lambda^2} \log(L(x)) = -\frac{n}{\lambda^2} < 0$$

כלומר אכן קיבלנו מקסימום.

כדי למקסם את הפוסטריור:

$$p(\lambda|x) = L \cdot \frac{c_0 \lambda^{a-1} e^{-\lambda b}}{c_1} = \tilde{C} \lambda^{a+n-1} e^{-\lambda(b + \sum x_i)}$$

$$\ln(p) = \tilde{C} + (a + n - 1) \ln \lambda - \lambda(b + \sum x_i)$$

$$\frac{d}{d\lambda} \ln(p) = \frac{a + n - 1}{\lambda} - b + \sum x_i = 0$$

$$\tilde{\lambda} = \frac{a + n - 1}{b + \sum x_i}$$

$$\frac{d^2}{d\lambda^2} \ln(p) = \frac{1 - a - n}{\lambda^2} < 0$$

ואכן באמת קיבלנו מקסימום (כי $a > 0, n \geq 1$).
זה סוף התרגול, לכן עכשיו נלך לישון שמחים ומאושרים.



4 תרגול 4

אני רוצה לשאול האם האומד שמצאנו הוא אומד מדויק. נתבונן בתוחלת.
 דוגמה: יש לנו את העומד $\bar{x} = \frac{1}{n} \sum x_i$ עם x_i דגימות $i.i.d$, הוא תמיד לא מוטה.
 הוכחה:

$$B(\bar{x}) = \mathbb{E}[\bar{x}] - \mu = \mathbb{E}\left[\frac{1}{n} \sum x_i\right] - \mu = \frac{1}{n} \sum \mathbb{E}[x_i] - \mu = \frac{1}{n} n\mu - \mu = 0$$

הפעם נבדוק האם השונות היא אומד מוטה:

$$\hat{\sigma} = \frac{1}{n} \sum_i (x_i - \bar{x})^2 = \frac{1}{n} \sum_i (x_i - \sum_j x_j)^2 = \frac{1}{n} \sum_i x_i^2 - \frac{2}{n^2} \sum_{i,j} x_i x_j + \frac{1}{n^3} \left(\sum_j x_j \right)^2 = \dots = \frac{n-1}{n} \sigma$$

דוגמה: יש לנו $x_i \sim U[0, b]$. נמצא אומד נראות מירבית ואז נחשב את ההטיה.

$$P(x_i) = \frac{\mathbb{1}_{[0,b]}}{b} \Rightarrow \prod_{i=1}^n P(x_i) = \frac{1}{b^n} \prod_{i=1}^n \mathbb{1}_{[0,b]}(x_i)$$

מתקיים כי $x_n \leq b$ ונרצה גם b מינימלי. בעצם, זה אומד מספיק.

$$B(\hat{b}) = \mathbb{E}[\hat{b}] - b = \frac{b}{2} - b = -\frac{b}{2} \neq 0$$

4.0.1 שגיאה ריבועית:

$$MSE(\theta) = \mathbb{E}\left[\left(\hat{\theta} - \theta\right)^2\right] = B^2(\hat{\theta}) + \mathbb{V}[\hat{\theta}], B(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$$

דוגמה: $x_i \sim \text{Pois}(\lambda)$ סדרת משתנים $i.i.d$ ונגדיר אומד $T = \bar{x} = \frac{1}{n} \sum x_i$. נמצא $MSE(T)$:
 לפי מה שאמרנו מוקדם יותר: \bar{x} הוא אומד לא מוטה לתוחלת (λ) , לכן

$$\mathbb{V}[T] = \mathbb{V}\left[\frac{1}{n} \sum x_i\right] = \frac{1}{n^2} \mathbb{V}[\sum x_i] = \frac{1}{n^2} \sum \mathbb{V}[x_i] = \frac{1}{n^2} n\lambda = \frac{\lambda}{n}$$

ולכן

$$MSE(T) = \mathbb{V}[T]$$

זה סוף התרגול, לכן עכשיו נלך לישון שמחים ומאושרים.



5 תרגול 5.

5.0.1 איך משפרים אומד?

תכונות של אומד :

1. חסר הטיות

2. מספיק

3. בעל שונות מינימלית

4. שלם

שלמות : אומד T הוא שלם $\iff \forall \theta \forall g : \mathbb{E}[g(T)] = 0 \Rightarrow g(T) = 0$.

5.0.2 חסם קרמר ראוי:

נגדיר אינפורמציות פישור להיות $I(\theta) = \mathbb{E} \left[\frac{\partial^2}{\partial^2 \theta} \ln(f) \right]$

יהי T אומד של θ על הפרמטרים $x_i \sim f(x|\theta)$. נגדיר $h(\theta) = \mathbb{E}[T]$ לפיכך,

$$h'(\theta) = \frac{\partial}{\partial \theta} \mathbb{E}[T] = \dots = \mathbb{E}[T \cdot \ln(f)]$$

החסם:

$$\mathbb{V}[T] \geq \frac{[h'(\theta)]^2}{I(\theta)}$$

דוגמה: $x_i \sim \text{Exp}(\frac{1}{\lambda})$ נמצא חסם קרמר ראוי עבור אומד לא מוטה $\hat{\lambda}$:

$$h(\lambda) = \mathbb{E}[\hat{\lambda}] = \lambda \Rightarrow h'(\lambda) = 1$$

כעת,

$$f = \frac{1}{\lambda} e^{-\frac{x}{\lambda}} \Rightarrow \ln(f) = -\ln(\lambda) - \frac{x}{\lambda}$$

נגזור:

$$\frac{\partial}{\partial \lambda} \ln(f) = -\frac{1}{\lambda} + \frac{x}{\lambda^2}$$

נגזור שוב:

$$\frac{\partial^2}{\partial^2 \lambda} \ln(f) = \frac{1}{\lambda^2} - \frac{2x}{\lambda^3}$$

ולפי הגדרת אינפורמציות פישור:

$$I(\lambda) = -\mathbb{E} \left[\frac{1}{\lambda^2} - \frac{2x}{\lambda^3} \right] = -\frac{1}{\lambda^2} + \frac{2\lambda}{\lambda^3} = \frac{1}{\lambda^2}$$

לכן חסם קרמר ראוי הינו

$$\boxed{\frac{1}{\lambda^2}}$$

יהי $\hat{\theta}$ אומד לא מוטה ויהי T אומד מספיק, אזי האומד

$$A = \mathbb{E} [\hat{\theta}|T]$$

הוא אומד לא מוטה וגם מתקיים

$$\mathbb{V}[A] \leq \mathbb{V}[\hat{\theta}]$$

הערה:

$$\hat{\theta} = \mathbb{E} [\mathbb{E} [\hat{\theta}|T] | T]$$

דוגמה: יהיו $x_i \sim \text{Pois}(\lambda)$ משתנים מקריים i.i.d. נרצה למצוא $UMVUE$ עבור $g(\lambda) = \lambda e^{-\lambda}$.

1. נראה ש- $\hat{\theta} = \mathbb{1}_{(x=1)}$ לא מוטה עבור $g(\lambda)$:

$$\mathbb{E} [\hat{\theta}] = p(x_1 = 1) = p(x_1 \sim \text{Pois}(\lambda) = 1) = \frac{1}{1!} \cdot \lambda^1 e^{-\lambda} = \lambda e^{-\lambda} = g(\lambda)$$

2. נראה כי $T = \sum x_i$ מספיק ושלם:

טענה: אם $x_i \sim \text{Pois}(\lambda)$ מתפלגים i.i.d. אזי $\sum x_i \sim \text{Pois}(n\lambda)$.
הוכחה: תרגיל לקורא הנבון.

$$\mathbb{1}(x|\lambda) = \prod_{i=1}^n p(x_i|\lambda) = h(x) \cdot \lambda^{\sum x_i} e^{-n\lambda} = h(x) \cdot e^{\ln(\lambda) \cdot \sum x_i - n\lambda}$$

כלומר $\sum x_i$ מספיק ושלם!

3. נמצא $UMVUE$ ל- $g(\lambda)$:

$$\begin{aligned} A &= \mathbb{E} [\hat{\theta}|T] \\ &= \left[\frac{P(x_1 = 1 \cap \sum x_i = s)}{p(\sum x_i = s)} \right] \\ &= \frac{\lambda e^{-\lambda} \cdot P\left(\frac{\sum x_i}{2} = s-1\right)}{\frac{1}{s!} (n\lambda)^s e^{-n\lambda}} \\ &= \frac{\lambda e^{-\lambda} \cdot \frac{1}{(s-1)!} ((n-1)\lambda)^{s-1} e^{-(n-1)\lambda}}{\frac{1}{s!} (n\lambda)^s e^{-n\lambda}} \\ &= \frac{s(n-1)^{s-1} \lambda^s}{n^s \lambda^s} \\ &= \frac{s}{n} \left(\frac{n-1}{n} \right)^{s-1} \end{aligned}$$

כלומר האומד $UMVUE$ שלנו יהיה

$$T = \frac{s}{n} \left(\frac{n-1}{n} \right)^{s-1}$$

כנדרש.

■

זה סוף התרגול, לכן עכשיו נלך לישון שמחים ומאושרים.

6 תרגול 6.

הגדרה: אומד נלווה M לפרמטר θ אם $P(M) \neq f(\theta)$ כלומר M לא תלוי ב- θ .
 משפט (bozo): יהיו $x_i \sim f(X|\theta)$ סדרת דגימות i.i.d. אזי נגדיר T אומד מספיק ו- u אומד נלווה אזי T - u ב"ת (כמשתנים מקריים).
 דוגמה: $x_{1,2} \sim \mathcal{N}(\mu, \sigma^2)$ i.i.d. נגדיר

$$T = \sum_i x_i \sim \mathcal{N}(2\mu, 2\sigma^2)$$

$$u = x_1 - x_2 \sim \mathcal{N}(0, 2\sigma^2)$$

אזי u הוא אומד נלווה.

הגדרה: רווח סמך ברמת ביטחון α (לפרמטר θ) הוא קטע $[L, U] \subseteq \mathbb{R}$ המקיים $P(\theta \in [L, U]) = 1 - \alpha$.
 כדי למצוא רווח סמך טוב נרצה $|U - L|$ מינימלי.

דוגמה: $x_i \sim \mathcal{N}(\mu, \sigma^2)$. נרצה רווח סמך ל- μ ברמת ביטחון α .

בתור התחלה: מתקיים עבור $n \geq 30$ (כאשר n זה מספר הדגימות) כי $\bar{x} \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$. לכן $\frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$ (משתנה מקרי מתוקן).
 נמצא UMVUE ל- μ (זה \bar{x}). לכן:

$$\begin{aligned} 1 - \alpha &= P(\mathcal{N}(0, 1) \leq z_{1-\alpha}) \\ &= P(-z_{1-\frac{\alpha}{2}} \leq \mathcal{N}(0, 1) \leq z_{1-\frac{\alpha}{2}}) \\ &= P\left(-z_{1-\frac{\alpha}{2}} \leq \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq z_{1-\frac{\alpha}{2}}\right) \\ &= P\left(\bar{x} - \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}} \leq \mu \leq \bar{x} + \frac{\sigma}{\sqrt{n}} z_{1-\frac{\alpha}{2}}\right) \end{aligned}$$

זה סוף התרגול, לכן עכשיו נלך לישון שמחים ומאושרים.



7 תרגול 7

נתונים i.i.d. $x_i \sim f(x|\theta) = \frac{2x}{\theta^2} \cdot \mathbb{1}_{[0,\theta]}$
נמצא אומד MLE :

$$P(\{x_i\}) = L(x|\theta) = \prod_i \left(\frac{2x}{\theta^2} \cdot \mathbb{1}_{[0,\theta]}(x_i) \right) = \theta^{-2n} \cdot \prod_i (2x_i \mathbb{1}_{[0,\theta]}(x_i))$$

על מנת להיפטר מ- $\mathbb{1}_{[0,\theta]}(x_i)$ נדרוש $\forall i: 0 \leq x_i \leq \theta$ כלומר $x_{max} \leq \theta$.
בנוסף, θ נמצא במכנה, ז"א על מנת ש- $P(\{x_i\})$ יהיה מקסימלי נדרוש θ מינימלי, כלומר $\hat{\theta} = x_{max}$.
כעת בואו נסתכל על $T = c \cdot \bar{x}$. עבור איזה c האומד T הוא הכי טוב?
אנחנו רוצים MSE מינימלי.

$$\mathbb{E}[T] = \frac{c}{n} \mathbb{E}[\sum x_i] = c \mathbb{E}[x_i] = c \int_0^\theta x f(x) dx = c \int_0^\theta \frac{2x^2}{\theta^2} dx = \frac{2c\theta}{3}$$

מחישוב דומה

$$\mathbb{V}[T] = \frac{c^2 \theta^2}{18n}$$

לכן

$$MSE[T] = B^2(\hat{\theta}) + \mathbb{V}[T] = \left(\frac{2c\theta}{3} - \theta \right)^2 + \frac{c^2 \theta^2}{18n} = \theta^2 \left(\left(\frac{2c}{3} - 1 \right)^2 + \frac{c^2}{18n} \right)$$

אנחנו רוצים למצוא את ה- c שימזער את הביטוי הזה לכן נגזור לפי c ונשווה ל-0:

$$\frac{\partial}{\partial c} MSE[T] = \theta^2 \left(\frac{4}{3} \left(\frac{2c}{3} - 1 \right) + \frac{c}{9n} \right) = 0 \Rightarrow c_{min} = \frac{12n}{1+8n}$$

כעת נבדוק האם הוא אכן מינימום:

$$\begin{aligned} \frac{\partial^2}{\partial^2 c} MSE[T] &= \theta^2 \cdot \left(\frac{8}{3} + \frac{1}{9n} \right) \\ \frac{\partial^2}{\partial^2 c} MSE[T]|_{c=c_{min}} &= \theta^2 \cdot \left(\frac{8}{3} + \frac{1}{9n} \right) > 0 \end{aligned}$$

והוא אכן מביא מינימום, לכן $c = \frac{12n}{1+8n}$ מביא לנו MSE מינימלי עבור T .

שאלה. יש לנו $x_i \sim \frac{\theta}{2(1+|x|)^{\theta+1}}$ מתפלגים i.i.d. עבור $0 \leq x \in \mathbb{R}$.
נמצא UMVUE ל- θ .

פתרון: נגדיר $w = \ln(1+|x|) \sim \text{Exp}(\theta)$.

נמצא $T(w)$ שיהיה UMVUE ל- θ .

נשים: ♥

$$L(w) = \theta^n e^{-\theta \sum w_i}$$

בנוסף, האומד $T = \sum w_i \sim \Gamma(n, \theta)$ מספיק ושלם. נתבונן על $\hat{\theta} = \mathbb{1}_{[w_1=0]}$. הוא אומד לא מוטה. בנוסף,

$$P(w_1 = 0) = \theta$$

וגם

$$\mathbb{E}[\hat{\theta}] = \theta$$

כלומר מצאנו כי $\hat{\theta} = \mathbb{1}_{[w_1=0]}$ לא מוטה.

לכן לפי הלמה של להמן שפאה

$$A = \mathbb{E}[\hat{\theta}|T] = \mathbb{E}[w_1 = 0 | \sum w_i = s] = \frac{P(w_1 = 0 \wedge \sum w_i = s)}{P(\sum w_i = s)} = \frac{P(w_1 = 0) P\left(\sum_{i=2}^n w_i = s\right)}{P\left(\sum_{i=1}^n w_i = s\right)}$$

★ : כי $\hat{\theta}$ הוא אינדיקטור.

כעת לפי התרגיל שמופיע בשיעורי בית אם $w_i \sim \exp(\theta)$ אזי $\sum_{i=1}^n w_i \sim \Gamma(n, \theta)$ כלומר $\sum_{i=2}^n w_i \sim \Gamma(n-1, \theta)$ ולכן

$$A = \frac{P(w_1 = 0) P\left(\sum_{i=2}^n w_i = s\right)}{P\left(\sum_{i=1}^n w_i = s\right)} = \frac{\theta \cdot \frac{\theta^{n-1}}{\Gamma(n-1)} s^{n-1} e^{-s\theta}}{\frac{\theta^n}{\Gamma(n)} s^n e^{-s\theta}} \stackrel{*}{=} \frac{n-1}{s} = \frac{n-1}{T} = \frac{n-1}{\sum_{i=1}^n \ln(1 + |x_i|)}$$

ולכן $A = \frac{n-1}{\sum_{i=1}^n \ln(1 + |x_i|)}$ הוא האומדן UMVUE ל- θ .

8 תרגול 8.

8.1 רווחי סמך.

תזכורת: רווח סמך לפרמטר θ ברמת אמינות α מקיים

$$1 - \alpha = P(\theta \in [L, U])$$

איך מחשבים רווח סמך?

דוגמה: $x \sim U[0, \theta]$ דגימה יחידה. נחפש רווח סמך ל- θ ברמת בהירות 95% (כלומר $1 - \alpha = 0.95$).

פתרון: נשים \heartsuit כי $1 - \alpha = P(t\theta \leq x \leq (t + 0.95)\theta) \forall 0 < t < 0.05$.

לכן

$$\begin{aligned} 0.95 &= P(t\theta \leq x \leq \theta(0.95 + t)) \\ &= P\left(\frac{t}{x} \leq \frac{1}{\theta} \leq \frac{0.95 + t}{x}\right) \\ &= P\left(\frac{x}{0.95 + t} \leq \theta \leq \frac{x}{t}\right) \end{aligned}$$

כלומר הרווח סמך שלי יהיה $\left[\frac{x}{0.95+t}, \frac{x}{t}\right]$.

תרגיל: יש לנו $x_i \sim \mathcal{N}(\mu, \sigma^2)$ דגימות i.i.d. עם μ ידוע ו- σ לא ידוע. נחפש רווח סמך ל- μ ברמה של 95%.

פתרון: נבנה את ההתפלגות t_{n-1} שתעזור לנו לפתור את התרגיל:

תחילה, $y = \frac{\bar{x} - \mu}{\sigma} \sim \mathcal{N}(0, 1)$ אבל זה לא מספיק, כי אנחנו עדיין לא יודעים את σ . בגלל ש- $\chi_{n-1}^2 \sim \frac{\sum (x_i - \bar{x})^2}{\sigma^2}$ נקבל

$$t_{n-1} \sim \frac{\mathcal{N}(0, 1)}{\sqrt{\frac{\chi_{n-1}^2}{n-1}}} = \frac{\frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{\sum (x_i - \bar{x})^2}{\sigma^2 \cdot \frac{n-1}{n}}}} = \frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}}$$

כאשר $S^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$ הוא אומד UMVUE של σ^2 .

לכן

$$0.95 = P(L \leq \mu \leq U)$$

$$\begin{aligned} &= P\left(\underbrace{\frac{\bar{x} - U}{\frac{s}{\sqrt{n}}}}_{:=c_1} \geq \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} \geq \underbrace{\frac{\bar{x} - L}{\frac{s}{\sqrt{n}}}}_{:=c_2}\right) \\ &= P_{\star}(c_1 \leq t_{n-1} \leq c_2) \\ &= P_{\star\star}\left(t_{n-1, 0.025} \leq \frac{\bar{x} - \mu}{\frac{s}{\sqrt{n}}} \leq t_{n-1, 0.975}\right) \\ &= P\left(\bar{x} - t_{n-1, 1-\frac{\alpha}{2}} \cdot \frac{s}{\sqrt{n}} \leq \mu \leq \bar{x} + t_{n-1, 1-\frac{\alpha}{2}} \cdot \frac{s}{\sqrt{n}}\right) \end{aligned}$$

* : בגלל הסימטריות של התפלגות t , נקבל שהרווח סמך $[c_1, c_2]$ שווה ערך לרווח הסמך $[-c_2, -c_1]$.

** : מחפשים בטבלת t את הערכים של c_1, c_2 .

9 תרגול 9.

9.1 בדיקת השערות:

מבחן z : אנחנו יודעים את σ^2 ומחפשים את μ עם דגימות $x_i \sim \mathcal{N}(\mu, \sigma^2)$. לכן נשער

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu = \mu_1$$

איך המבחן עובד? ניקח

$$\frac{\bar{x} - \mu_0}{\frac{\sigma}{\sqrt{n}}} = z \sim \mathcal{N}(0, 1)$$

ניזכר שיש לנו 95% שבהם אני רוצה למצוא את H_0 ואם הוא נמצא ב-5% האחרים נקרא להם אזור הדחייה. כזכור אנחנו מחפשים c כך ש-

$$P(z > c) = 1 - \alpha$$

נחשב את z לפי המדגם (מקבלים מספר).

בצורה שקולה: נמצא קצוות לרווח סמך (לרוב יהיה $[-c, c]$) ואז נגדיר את האומד מבחן שיסומן ב- z , ואם $z \leq c$ אז לא נדחה (כי אנחנו בתוך ה-95%) ואם $z > c$ נדחה את H_0 .

דוגמה. יש לנו דגימות $x_i \sim \mathcal{N}(\mu, \sigma^2)$ עם שני פרמטרים לא ידועים. ההשערה: $H_0 : \mu = \mu_0$ ודגימות $[90.1, 88.5, 59, 78, 100]$ ברווח סמך $H_1 : \mu \neq \mu_0$. $\alpha = 0.95$. מספר הדגימות שלנו $n < 30$. ההשערות שלנו יהיו

$$H_0 : \mu = 83.12$$

$$H_1 : \mu < 83.12$$

תזכורת: עבור n גדול:

$$\frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0, 1)$$

עבור n קטן או σ לא ידוע:

$$S_n^2 = \frac{\sum (x_i - \bar{x})^2}{n-1} \rightarrow \frac{\chi_{n-1}^2}{n-1}$$

ובנוסף

$$t_{n-1} \sim \frac{\frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{S^2}} = \frac{\mathcal{N}(0, 1)}{\sqrt{\frac{\chi_{n-1}^2}{n-1}}}$$

כלומר הסטייה המדגמית תהיה

$$t_{n-1} = \frac{\bar{x} - \mu}{\frac{S}{\sqrt{n}}}$$

כיוון שיש לנו קצת דגימות נלך לאפשרות השנייה.

נמצא רווח סמך ל- μ :

$$(-\infty, t_{n-1, 0.95})$$

נציב נתונים+ את H_0 ולכן ברווח סמך $\alpha = 0.005$ ניקח את ההשערה

$$H_0 : \mu = 92.5$$

$$H_1 : \mu < 92.5$$

ולכן המבחן יהיה

$$t = \frac{83.12 - 92.5}{\frac{S}{\sqrt{n}}} < 0$$

כלומר דחינו את H_0 .